



福建師範大學
FUJIAN NORMAL UNIVERSITY

《人工智能》

【第二章-线性模型】

广义线性回归

黄锐泓


本节要点

1. 广义线性回归
2. 逻辑回归
3. 多分类逻辑回归
4. 评价指标



广义线性回归

狭义线性回归的基本假设是 y 与 x 直接呈线性关系。如果不是线性关系，那么使用线性回归模型进行拟合后会得到较大的误差。



广义线性回归

狭义线性回归的基本假设是 y 与 x 直接呈线性关系。如果不是线性关系，那么使用线性回归模型进行拟合后会得到较大的误差。

线性回归模型 $y \approx f(x) = \vec{w}^T \vec{x} + b$


-> 希望预测值逼近真实标记

能否让预测值逼近 y 的衍生物？

令 $\ln y \approx f(x) = \vec{w}^T \vec{x} + b$

-> 对数线性回归

实际上是在用 $e^{\vec{w}^T \vec{x} + b}$ 逼近 y



广义线性回归

广义线性回归：寻找这样一个函数 g ，使得 $g(y)$ 与 x 之间是线性关系，此时可以使用线性回归进行参数估计。



广义线性回归

广义线性回归：寻找这样一个函数 g ，使得 $g(y)$ 与 x 之间是线性关系，此时可以使用线性回归进行参数估计。

例如，假设 y 与 x 的实际关系是 $y = \omega x^3$ 。令函数 $g(y) = y^{\frac{1}{3}} = \omega' x$ ，其中 $\omega' = \omega^{\frac{1}{3}}$ 是要估计的未知参数。那么 $g(y)$ 与 x 呈线性关系，可以使用线性回归对 ω' 进行参数估计，从而间接得到 ω 。



广义线性回归

广义线性回归：寻找这样一个函数 g ，使得 $g(y)$ 与 x 之间是线性关系，此时可以使用线性回归进行参数估计。

$$\text{一般形式： } y = g^{-1}(\vec{\omega}^T \vec{x} + b)$$

$g \rightarrow$ 单调可微的**联系函数** (link function)

$$\text{令 } g(\cdot) = \ln(\cdot)$$

$$\text{则得到 对数线性回归 } \ln y \approx f(x) = \vec{\omega}^T \vec{x} + b$$

.....



逻辑回归

逻辑回归是一种广义线性回归，通过回归对数几率(Logits)的方式将线性回归应用于分类任务。

对于一个二分类问题，令 $Y \in \{0, 1\}$ 表示样本 x 对应的类别变量。设 x 属于类别1的概率为 $P(Y = 1 | x) = p$ ，则有 $P(Y = 0 | x) = 1 - p$ 。

比值 $\frac{p}{1-p}$ 称为几率 (Odds)，几率的对数即为对数几率(Logits)，即 $\ln \frac{p}{1-p}$



逻辑回归

逻辑回归模型中， x 属于类别1的对数几率是输入 x 的线性函数，
通过回归式计算对数几率来间接得到 p 的值，

$$\text{即 } \ln \frac{p}{1-p} = \vec{\omega}^T \vec{x} + b, \text{ 解得 } p = \frac{1}{1+e^{-(\vec{\omega}^T \vec{x} + b)}}$$

$$\begin{aligned} \ln \frac{p}{1-p} &= \vec{\omega}^T \vec{x} + b \\ \frac{p}{1-p} &= e^{(\vec{\omega}^T \vec{x} + b)} \\ p &= (1-p)e^{(\vec{\omega}^T \vec{x} + b)} \\ p + p \cdot e^{(\vec{\omega}^T \vec{x} + b)} &= e^{(\vec{\omega}^T \vec{x} + b)} \\ p \cdot (1 + e^{(\vec{\omega}^T \vec{x} + b)}) &= e^{(\vec{\omega}^T \vec{x} + b)} \\ p &= \frac{e^{(\vec{\omega}^T \vec{x} + b)}}{1 + e^{(\vec{\omega}^T \vec{x} + b)}} = \frac{1}{1 + e^{-(\vec{\omega}^T \vec{x} + b)}} \end{aligned}$$

化简过程



逻辑回归

逻辑回归模型中， x 属于类别1的对数几率是输入 x 的线性函数，
通过回归式计算对数几率来间接得到 p 的值，

$$\text{即 } \ln \frac{p}{1-p} = \vec{\omega}^T \vec{x} + b, \text{ 解得 } p = \frac{1}{1+e^{-(\vec{\omega}^T \vec{x} + b)}}$$

为了方便描述，令 $\vec{\omega} = (\omega_1, \omega_2, \dots, \omega_n, b)^T$,

$$\vec{x} = (x_1, x_2, \dots, x_n, 1)^T$$


$$\text{则有 } p = \frac{1}{1+e^{-\vec{\omega}^T \vec{x}}}$$



逻辑回归

逻辑斯蒂函数(logistic function)

$$\text{标准形式: } f = \frac{e^t}{1+e^t} = \frac{1}{1+e^{-t}}$$



在逻辑回归模型中,

$$\text{样本属于类别1的概率 } P(Y = 1 | x) = p = \frac{1}{1+e^{-\vec{\omega}^T \vec{x}}}$$

线性函数的值越接近正无穷, 概率值就越接近1;

线性函数的值越接近负无穷, 概率值就越接近0.



逻辑回归

模型参数估计：极大似然估计法

给定样本集合 $D = \{(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_m, y_m)\}$,

似然函数为 $L(\vec{\omega}) = \prod_{i=1}^m p^{y_i} (1 - p)^{(1-y_i)}$

对数似然函数为 $l(\vec{\omega}) = \sum_{i=1}^m (y_i \ln p + (1 - y_i) \ln(1 - p))$

$$= \sum_{i=1}^m \left(y_i \vec{\omega}^T \vec{x}_i - \ln \left(1 + e^{\vec{\omega}^T \vec{x}_i} \right) \right)$$

对 $l(\vec{\omega})$ 求极大值，得到 $\vec{\omega}$ 的估计值，在逻辑回归学习中通常采用梯度下降法及牛顿法求解参数。



多分类逻辑回归

二分类逻辑回归也可扩展到多分类逻辑回归

将 $\vec{\omega} = \vec{\omega}_1 - \vec{\omega}_0$ 代入 $p = \frac{1}{1+e^{-\vec{\omega}^T \vec{x}}}$ 有：

$$P(Y = 1 | \vec{x}) = p = \frac{1}{1+e^{-\vec{\omega}^T \vec{x}}} = \frac{e^{\vec{\omega}^T \vec{x}}}{1+e^{\vec{\omega}^T \vec{x}}} = \frac{e^{\vec{\omega}_1^T \vec{x}}}{e^{\vec{\omega}_0^T \vec{x}} + e^{\vec{\omega}_1^T \vec{x}}}$$

$$P(Y = 0 | \vec{x}) = 1 - p = \frac{e^{\vec{\omega}_0^T \vec{x}}}{e^{\vec{\omega}_0^T \vec{x}} + e^{\vec{\omega}_1^T \vec{x}}}$$



多分类逻辑回归

通过归纳可将逻辑回归推广到任意多分类问题中。当类别数目为 K 时（类别编号为 $0, 1, \dots, K-1$ ），有：

$$P(Y = i \mid \vec{x}) = \frac{\exp(\vec{\omega}_i^T \vec{x})}{\sum_{k=0}^{K-1} \exp(\vec{\omega}_k^T \vec{x})}, i = 0, 1, 2, \dots, K-1$$

另一种表达形式：

$$P(Y = 0 \mid \vec{x}) = \frac{1}{1 + \sum_{k=1}^{K-1} \exp(\vec{\omega}_k^T \vec{x})},$$

$$P(Y = i \mid \vec{x}) = \frac{\exp(\vec{\omega}_i^T \vec{x})}{1 + \sum_{k=1}^{K-1} \exp(\vec{\omega}_k^T \vec{x})}, i = 0, 1, 2, \dots, K-1$$



评价指标

对于一个分类任务，往往可以训练许多不同模型，如何从众多模型中挑选出综合表现最好的？

什么样的模型是“好”的，不仅取决于算法和数据，还取决于任务需求

模型的评价指标：混淆矩阵、准确率、精确率与召回率、PR曲线、ROC曲线、……

使用不同的评价指标往往会导致不同的评判结果



评价指标——混淆矩阵

混淆矩阵是理解大多数评价指标的基础,其包含四部分的信息:

- 1) 真阴率 (TN) 表明实际是负样本预测成负样本的样本数
- 2) 假阳率 (FP) 表明实际是负样本预测成正样本的样本数
- 3) 假阴率 (FN) 表明实际是正样本预测成负样本的样本数
- 4) 真阳率 (TP) 表明实际是正样本预测成正样本的样本数

		预测值	
		0	1
真实值	0	True negative (TN)	False positive (FP)
	1	False negative (FN)	True positive (TP)

评价指标——准确率

准确率是最为常见的一项指标，即预测正确的结果占总样本的百分比，其公式为：

$$accuracy = \frac{TP+TN}{TP+TN+FP+FN}$$

虽然准确率可以判断总的正确率，但是在样本不平衡的情况下，并不能作为很好的指标来衡量结果。

例：假设在所有样本中，正样本占90%，负样本占10%，样本是严重不平衡的。模型将全部样本预测为正样本即可得到90%的高准确率，如果仅使用准确率这一单一指标，模型就可以像这样偷懒获得很高的评分。



评价指标——精确率与召回率

精确率又叫**查准率**，它是针对预测结果而言的。精确率表示在所有被预测为正的样本中实际为正的样本的概率。意思就是在预测为正样本的结果中，有多少把握可以预测正确，公式为：

$$precision = \frac{TP}{TP+FP}$$

召回率又叫**查全率**，它是针对原样本而言的。召回率表示在实际为正的样本中被预测为正样本的概率，公式为：


$$recall = \frac{TP}{TP+FN}$$



评价指标——PR曲线

PR曲线：以精确率（*precision*）为纵坐标，以召回率（*recall*）为横坐标做出的曲线。

分类模型对每个样本点都会输出一个置信度。通过设定置信度阈值，就可以完成分类。不同的置信度阈值对应着不同的精确率和召回率。一般来说，置信度阈值较低时，大量样本被预测为正例，所以召回率较高，而精确率较低；置信度阈值较高时，大量样本被预测为负例，所以召回率较低，而精确率较高。




评价指标——PR曲线

PR曲线：以精确率（*precision*）为纵坐标，以召回率（*recall*）为横坐标做出的曲线。

PR曲线绘制

PR曲线的横坐标为召回率R，纵坐标为查准率P，绘制步骤如下：

1. 将预测结果按照预测为正类概率值排序；
2. 将概率阈值由1开始逐渐降低，按此顺序逐个把样本作为正例进行预测，每次可以计算出当前的P，R值；
3. 以P为纵坐标，R为横坐标绘制点，将所有点连成曲线后构成PR曲线。




评价指标——PR曲线

PR曲线：以精确率（*precision*）为纵坐标，以召回率（*recall*）为横坐标做出的曲线。


如何利用PR曲线对比算法的优劣

1. 如果一条曲线完全“包住”另一条曲线，则前者性能优于另一条曲线（P和R越高，代表算法分类能力越强）。
2. PR曲线发生了交叉时：以PR曲线下的面积作为衡量指标，但这个指标通常难以计算
3. 使用“平衡点”（Break-Even Point），他是查准率=查全率时的取值，值越大代表效果越优
4. BEP过于简化，更常用的是F1度量



评价指标——ROC曲线

ROC (Receiver Operating Characteristic Curve) 曲线：以假阳率为横坐标，以真阳率为纵坐标做出的曲线。



横轴：假阳率 (FPR)

$$FPR = \frac{FP}{TN+FP}$$


纵轴：真阳率 (TPR)

$$TPR = \frac{TP}{TP+FN}$$

显然，ROC曲线的横纵坐标都在 $[0, 1]$ 之间，面积不大于1。



评价指标——ROC曲线



(0, 0): 假阳率和真阳率都为0, 即分类器全部预测成负样本。

(0, 1): 假阳率为0, 真阳率为1, 全部完美预测正确。

(1, 0): 假阳率为1, 真阳率为0, 全部完美预测错误。


(1, 1): 假阳率和真阳率都为1, 即分类器全部预测成正样本。

当 $TPR=FPR$ 为一条斜对角线时, 表示预测为正样本的结果一半是对的, 一半是错的, 即为随机分类器的预测效果。ROC曲线在斜对角线以下, 表示该分类器效果差于随机分类器; 反之, 效果好于随机分类器。



评价指标——ROC曲线

通过ROC曲线对比不同模型的性能



评价指标——AUC曲线

AUC(Area Under Curve)作为机器学习模型评价的指标之一，常被用于分类任务以及搜索推荐任务中


AUC(Area Under Curve),顾名思义为曲线下的面积，曲线即为ROC曲线。因此，AUC定义为**ROC曲线下与坐标轴围成的面积**。

AUC的取值范围在0.5和1之间。AUC越接近1.0，模型分类性能越好；等于0.5时，模型性能最差。

AUC的物理意义，对一个正样本进行预测“正样本预测置信度大于负样本预测置信度的概率”的值。



评价指标——AUC曲线



小结

1. 广义线性规划
2. 逻辑回归
3. 多分类逻辑回归
4. 评价指标



谢谢！

