



福建師範大學  
FUJIAN NORMAL UNIVERSITY

# 《机器学习》

## 【第二章-线性模型】

线性回归

黄锐泓

# 本节要点

---

1. 基本概念
2. 最小二乘法
3. 多元线性回归



# 基本概念

---

线性模型 —— 通过属性的线性组合来进行预测的函数

Vs 非线性模型

-> 简单、可理解性好



# 基本概念

---

线性模型 —— 通过属性的线性组合来进行预测的函数

Vs 非线性模型

-> 简单、可理解性好

例如：

1. 房子的面积 $x$ 和房价 $y$ 呈线性关系
2. 员工的工作年限 $x$ 和薪水 $y$ 之间存在着近似线性的关系

$$\begin{aligned}y &= \omega x + b \\f(x) &= y \\f(x) &= \omega x + b\end{aligned}$$





# 基本概念

线性模型 —— 通过属性的线性组合来进行预测的函数

Vs 非线性模型


$$f(x) = \omega_1 x^1 + \omega_2 x^2 + \cdots + \omega_n x^n + b$$

-> 简单、可理解性好



# 基本概念

线性回归 —— 研究自变量与因变量之间的线性关系



# 基本概念

---

线性回归 —— 研究自变量与因变量之间的线性关系

假设：特征  $\vec{x} = (x^1, x^2, \dots, x^n)$  与其对应的标签  $y$  之间存在线性映射

$$\begin{aligned} y \approx f(x) &= \omega_1 x^1 + \omega_2 x^2 + \dots + \omega_n x^n + b \\ &= \sum_{i=1}^n \omega_i x^i + b = \vec{\omega}^T \vec{x} + b \end{aligned}$$



# 基本概念

$$y \approx f(x) = \omega_1 x^1 + \omega_2 x^2 + \cdots + \omega_n x^n + b$$

$$= \sum_{i=1}^n \omega_i x^i + b = \vec{\omega}^T \vec{x} + b$$

| $x^1$ | $x^2$ |
|-------|-------|
| 0.8   | 0.9   |

 ✓

| $x^1$ | $x^2$ |
|-------|-------|
| 青绿色   | 声音浑浊  |

 ?

# 基本概念

$$y \approx f(x) = \omega_1 x^1 + \omega_2 x^2 + \cdots + \omega_n x^n + b$$
$$= \sum_{i=1}^n \omega_i x^i + b = \vec{\omega}^T \vec{x} + b$$

| $x^1$ | $x^2$ |
|-------|-------|
| 0.8   | 0.9   |



身高: ✓

西瓜颜色: ✗

高  $\rightarrow$  1

青绿色  $\rightarrow$  1

中  $\rightarrow$  0.5

翠绿色  $\rightarrow$  0.5

低  $\rightarrow$  0

浅白色  $\rightarrow$  0

| $x^1$ | $x^2$ |
|-------|-------|
| 青绿色   | 声音浑浊  |



# 基本概念

$$y \approx f(x) = \omega_1 x^1 + \omega_2 x^2 + \cdots + \omega_n x^n + b$$
$$= \sum_{i=1}^n \omega_i x^i + b = \vec{\omega}^T \vec{x} + b$$

| $x^1$ | $x^2$ |
|-------|-------|
| 0.8   | 0.9   |



身高: ✓

西瓜颜色:

高  $\rightarrow$  1

青绿色  $\rightarrow$  [1 0 0]

中  $\rightarrow$  0.5

翠绿色  $\rightarrow$  [0 1 0]

低  $\rightarrow$  0

浅白色  $\rightarrow$  [0 0 1]

| $x^1$ | $x^2$ |
|-------|-------|
| 青绿色   | 声音浑浊  |



# 基本概念

$$y \approx f(x) = \omega_1 x^1 + \omega_2 x^2 + \cdots + \omega_n x^n + b$$
$$= \sum_{i=1}^n \omega_i x^i + b = \vec{\omega}^T \vec{x} + b$$

| $x^1$ | $x^2$ |
|-------|-------|
| 0.8   | 0.9   |



离散属性的处理:

若有“序”(order), 则连续化;

| $x^1$ | $x^2$ |
|-------|-------|
| 青绿色   | 声音浑浊  |



否则转化为k维向量



# 基本概念

$$\begin{aligned}y &\approx f(x) = \omega_1 x^1 + \omega_2 x^2 + \cdots + \omega_n x^n + b \\&= \sum_{i=1}^n \omega_i x^i + b = \vec{\omega}^T \vec{x} + b\end{aligned}$$

权重  $\vec{\omega} = (\omega_1, \omega_2, \dots, \omega_n)$  的各分量反映不同特征变量的重要程度

线性回归模型的预测值

线性回归的目标——求解  $\vec{\omega}$  和  $b$  使得  $f(\vec{x})$  与  $y$  尽可能接近

实际的观测值




# 最小二乘法

以一元线性回归（只有一个自变量）为例

$$y \approx f(x) = \omega x + b$$

如何求解  $\omega$  与  $b$  ？



# 最小二乘法

求解线性回归模型的基本方法 —— 最小二乘法

优化目标：让整个样本集合上的预测值与真实值之间的欧氏距离之和最小

给定空间中的一组样本点  $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$

$$\text{目标函数为 } J(\omega, b) = \sum_{i=1}^m (y_i - f(x_i))^2 = \sum_{i=1}^m (y_i - \omega x_i - b)^2$$

实际的观测值

线性回归模型的预测值



# 最小二乘法

求解线性回归模型的基本方法 —— 最小二乘法

优化目标：让整个样本集合上的预测值与真实值之间的欧氏距离之和最小

给定空间中的一组样本点  $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$

目标函数为  $J(\omega, b) = \sum_{i=1}^m (y_i - f(x_i))^2 = \sum_{i=1}^m (y_i - \omega x_i - b)^2$

$$J = J(\omega, b) + \lambda \|\vec{\omega}\|_2$$

正则项



# 最小二乘法

---

$$J(\omega, b) = \sum_{i=1}^m (y_i - f(x_i))^2 = \sum_{i=1}^m (y_i - \omega x_i - b)^2$$

令目标函数对  $\omega$  和  $b$  的偏导数为 0:

$$\frac{\partial J(\omega, b)}{\partial \omega} = \sum_{i=1}^m 2\omega x_i^2 + \sum_{i=1}^m 2(b - y_i)x_i = 0$$


$$\frac{\partial J(\omega, b)}{\partial b} = \sum_{i=1}^m 2(\omega x_i - y_i) + 2mb = 0$$



# 最小二乘法


$$\frac{\partial J(\omega, b)}{\partial \omega} = \sum_{i=1}^m 2\omega x_i^2 + \sum_{i=1}^m 2(b - y_i)x_i = 0$$

$$\frac{\partial J(\omega, b)}{\partial b} = \sum_{i=1}^m 2(\omega x_i - y_i) + 2mb = 0$$



求解

$$\begin{cases} \sum_{i=1}^m 2\omega x_i^2 + \sum_{i=1}^m 2(b - y_i)x_i = 0 \\ \sum_{i=1}^m 2(\omega x_i - y_i) + 2mb = 0 \end{cases}$$



$$\begin{cases} \omega = ? \\ b = ? \end{cases}$$



# 最小二乘法

---

先求解 $b$ , 我们有:  $\frac{\partial J(\omega, b)}{\partial b} = \sum_{i=1}^m 2(\omega x_i - y_i) + 2mb = 0$

$$\sum_{i=1}^m 2(\omega x_i - y_i) + 2mb = 0$$

$$\sum_{i=1}^m (\omega x_i - y_i) + mb = 0$$

$$mb = \sum_{i=1}^m (y_i - \omega x_i)$$

$$b = \frac{\sum_{i=1}^m (y_i - \omega x_i)}{m}$$

$$b = \frac{\sum_{i=1}^m y_i - \omega \sum_{i=1}^m x_i}{m}$$



# 最小二乘法

再求解 $\omega$ , 我们有:  $\frac{\partial J(\omega, b)}{\partial \omega} = \sum_{i=1}^m 2\omega x_i^2 + \sum_{i=1}^m 2(b - y_i)x_i = 0$

$$\sum_{i=1}^m 2\omega x_i^2 + \sum_{i=1}^m 2(b - y_i)x_i = 0$$

$$b = \frac{\sum_{i=1}^m y_i - \omega \sum_{i=1}^m x_i}{m}$$

将  $b$  代入

$$\sum_{i=1}^m x_i y_i - \omega \sum_{i=1}^m x_i^2 - b \sum_{i=1}^m x_i = 0$$

$$\sum_{i=1}^m x_i y_i - \omega \sum_{i=1}^m x_i^2 - \frac{(\sum_{i=1}^m y_i - \omega \sum_{i=1}^m x_i) \sum_{i=1}^m x_i}{m} = 0$$

$$\sum_{i=1}^m x_i y_i - \frac{\sum_{i=1}^m y_i \sum_{i=1}^m x_i}{m} = \omega \sum_{i=1}^m x_i^2 - \frac{\omega (\sum_{i=1}^m x_i)^2}{m}$$

$$\frac{m \sum_{i=1}^m x_i y_i - \sum_{i=1}^m y_i \sum_{i=1}^m x_i}{m} = \frac{m \omega \sum_{i=1}^m x_i^2 - \omega (\sum_{i=1}^m x_i)^2}{m}$$



# 最小二乘法

再求解 $\omega$ , 我们有:  $\frac{\partial J(\omega, b)}{\partial \omega} = \sum_{i=1}^m 2\omega x_i^2 + \sum_{i=1}^m 2(b - y_i)x_i = 0$

$$\frac{m\sum_{i=1}^m x_i y_i - \sum_{i=1}^m y_i \sum_{i=1}^m x_i}{m} = \frac{m\omega \sum_{i=1}^m x_i^2 - \omega (\sum_{i=1}^m x_i)^2}{m}$$
$$\frac{m\sum_{i=1}^m x_i y_i - \sum_{i=1}^m y_i \sum_{i=1}^m x_i}{m} = \frac{\omega [m\sum_{i=1}^m x_i^2 - (\sum_{i=1}^m x_i)^2]}{m}$$

$$\omega = \frac{m\sum_{i=1}^m x_i y_i - \sum_{i=1}^m y_i \sum_{i=1}^m x_i}{m\sum_{i=1}^m x_i^2 - (\sum_{i=1}^m x_i)^2}$$



# 最小二乘法

$$J(\omega, b) = \sum_{i=1}^m (y_i - f(x_i))^2 = \sum_{i=1}^m (y_i - \omega x_i - b)^2$$

计算得到  $\omega$  和  $b$  的估计值:

$\bar{x}$  是平均值, 即  $\frac{1}{m}(\sum_{i=1}^m x_i)$

$$\omega = \frac{m \sum_{i=1}^m x_i y_i - \sum_{i=1}^m x_i \sum_{i=1}^m y_i}{m \sum_{i=1}^m x_i^2 - \left(\sum_{i=1}^m x_i\right)^2} = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\overline{x^2} - \bar{x}^2}$$

$$b = \frac{1}{m} \left( \sum_{i=1}^m y_i - \omega \sum_{i=1}^m x_i \right) = \bar{y} - \omega \bar{x}$$



# 多元线性回归

---

自变量大于一个时 —— 多元线性回归

将  $b$  同样看作权重, 令  $\vec{\omega} = (\omega_1, \omega_2, \dots, \omega_n, b)$ ,

$$\vec{x} = (x^1, x^2, \dots, x^n, 1)$$

$$\text{则 } y \approx f(x) = \vec{\omega}^T \vec{x}$$



# 多元线性回归

给定空间中的一组样本点  $D = \{(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_m, y_m)\}$

优化目标为  $\min J(\vec{\omega}) = \min (\vec{Y} - X\vec{\omega})^T (\vec{Y} - X\vec{\omega})$

$X$ 为样本矩阵的增广矩阵  $X = \begin{pmatrix} x_1^1 & x_1^2 & \cdots & x_1^n & 1 \\ x_2^1 & x_2^2 & \cdots & x_2^n & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_m^1 & x_m^2 & \cdots & x_m^n & 1 \end{pmatrix}$

$Y$ 为对应的  $Y = (y_1, y_2, \dots, y_m)^T$



# 多元线性回归


求解优化目标可得  $\vec{\omega} = (X^T X)^{-1} X^T Y$

当  $X^T X$  可逆时，线性回归模型存在唯一解

当样本集合中的样本太少或者存在大量线性相关的维度，则可能会出现多个解的情况。

$$y_1 = Ax_1^1 + Bx_1^2 + Cx_1^3 + b$$

$$y_2 = Ax_2^1 + Bx_2^2 + Cx_2^3 + b$$



三个特征向量，只有两个数据样本



# 多元线性回归

---

求解优化目标可得  $\vec{\omega} = (X^T X)^{-1} X^T Y$

当  $X^T X$  可逆时，线性回归模型存在唯一解

当样本集合中的样本太少或者存在大量线性相关的维度，则可能会出现多个解的情况。

可以在原始线性回归模型的基础上增加正则化项目以降低模型的复杂度，使得模型变得简单。



# 多元线性回归

若加入L2正则化，则优化目标可写作：

$$\min J(\vec{\omega}) = \min (\vec{Y} - X\vec{\omega})^T (\vec{Y} - X\vec{\omega}) + \lambda \|\vec{\omega}\|_2$$

此时，线性回归又称为岭（Ridge）回归，求解式有：

$$\vec{\omega} = (X^T X + \lambda I)^{-1} X^T Y$$

$X^T X + \lambda I$  增加了一个扰动项  $\lambda I$ 。此时不仅能够降低模型的复杂度、防止过拟合，而且能够使  $X^T X + \lambda I$  可逆， $\vec{\omega}$  有唯一解。



# 多元线性回归

当正则化项为L1正则化时，线性回归模型又称为Lasso回归，此时优化目标可写作：


$$\min J(\vec{\omega}) = \min (\vec{Y} - X\vec{\omega})^T (\vec{Y} - X\vec{\omega}) + \lambda \|\vec{\omega}\|_1$$

L1正则化能够得到比L2正则化更为稀疏的解（指 $\vec{\omega} = (\omega_1, \omega_2, \dots, \omega_n)$ 中会存在多个值为0的元素），从而起到特征选择的作用。由于L1范数使用绝对值表示，目标函数不是连续可导，不能再使用最小二乘法进行求解，可使用近端梯度下降进行求解（PGD）。



# 多元线性回归

线性模型通常是其他模型的基本组成单元。堆叠若干个线性模型，同时引入非线性化激活函数，就可以实现对任意数据的建模。例如，神经网络中的一个神经元就是由线性模型加激活函数组合而成。



# 小结

---

1. 基本概念
2. 最小二乘法
3. 多元线性回归



---

谢谢！

