



福建師範大學
FUJIAN NORMAL UNIVERSITY

《机器学习》

【第四章-决策树与随机森林】

决策树

黄锐泓

本节要点

1. 算法概述
2. 特征选择
3. CART
4. 决策树剪枝



算法概述

决策树 (Decision Tree)


是一种常用的分类或回归算法

决策树的思想：决策树的核心思想是试图从训练集中归纳出一组分类规则，使得样本通过一步步决策，可以最终确定分类。



算法概述


决策树 (Decision Tree)



算法概述

决策树 (Decision Tree)

深度depth=2



算法概述

决策树 (Decision Tree)

思考，大家觉得构建一棵决策树的关键是什么？



特征选择

决策树构建的关键在于每次划分子树时，选择哪些特征进行划分

我们希望每次选择的属性可以让划分后的分支数据更有区分性，使各个分支的数据分类纯度更高，最好是每个分支的样本数据尽可能属于同一类别



特征选择

决策树构建的关键在于每次划分子树时，选择哪些特征进行划分
使用最能提供有效/关键信息的特征



特征选择

决策树构建的关键在于每次划分子树时，选择哪些特征进行划分

使用最能提供有效/关键信息的特征

如何判断哪些特征能提供关键信息？

信息增益 (Information Gain)



特征选择——熵 (Entropy)

信息论中，熵用于描述随机变量分布的不确定性

对于离散型随机变量 X ，假设其取值有 n 个，分别是 $x_1, x_2, \dots, x_n$ ，用频率表示

概率，随机变量的概率分布为 $p_i = P(X = x_i) = \frac{N_i}{N}$ 。（ N 为样本总数， N_i 为 X 取

值为 x_i 的数量）

则 X 的熵，定义为 $H(X) = \sum_{i=1}^n p_i \log \frac{1}{p_i} = - \sum_{i=1}^n p_i \log p_i$

事件出现的概率小，不确定性越多，信息量就大，反之则少
熵越大，随机变量的不确定性就越大



特征选择——熵 (Entropy)

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	是否好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.46	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.36	0.37	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

$$H(X) = \sum_{i=1}^n p_i \log \frac{1}{p_i}$$
$$= - \sum_{i=1}^n p_i \log p_i$$

共有17个数据样本，
“是否好瓜”这个变量为根节点，计算其信息熵

特征选择——熵 (Entropy)

$$H(X) = \sum_{i=1}^n p_i \log \frac{1}{p_i} = - \sum_{i=1}^n p_i \log p_i$$

共有17个数据样本，“是否好瓜”这个变量为A，计算其信息熵

其中是好瓜样本数8个，不是好瓜样本数9个。那么，是好瓜概率为8/17，不是好瓜的概率9/17

$$H(A) = -\frac{8}{17} \log_2 \frac{8}{17} - \frac{9}{17} \log_2 \frac{9}{17} = 0.9975$$



特征选择——熵 (Entropy)

X的熵，定义为 $H(X) = \sum_{i=1}^n p_i \log \frac{1}{p_i} = -\sum_{i=1}^n p_i \log p_i$

复习一下概率论

1. 联合概率分布，假设X和Y的取值个数分别为n和m，则其联合概率分布为：

$$p_{ij} = P(X = x_i, Y = y_j) = \frac{N_{ij}}{N} \quad (\text{其中} N \text{表示总样本数, } N_{ij} \text{表示} X = x_i \text{且} Y = y_j \text{的样本数目})$$

2. 类似的，边缘概率分布为：

$$p_{i.} = P(X = x_i) = \sum_{j=1}^m p_{ij} = \frac{N_{i.}}{N}$$



特征选择——熵 (Entropy)

X的熵，定义为 $H(X) = \sum_{i=1}^n p_i \log \frac{1}{p_i} = -\sum_{i=1}^n p_i \log p_i$

复习一下概率论

1. 联合概率分布，假设X和Y的取值个数分别为n和m，则其联合概率分布为：

$$p_{ij} = P(X = x_i, Y = y_j) = \frac{N_{ij}}{N} \quad (\text{其中} N \text{表示总样本数, } N_{ij} \text{表示} X = x_i \text{且} Y = y_j \text{的样本数目})$$

2. 类似的，边缘概率分布为：

$$p_{i.} = P(X = x_i) = \sum_{j=1}^m p_{ij} = \frac{N_{i.}}{N}$$

因此，定义给定X的条件下Y的条件熵为

已知随机变量 X 的条件下随机变量 Y 的不确定性

$$H(Y | X) = \sum_{i=1}^n p_i H(Y | X = x_i)$$



特征选择——熵 (Entropy)

X的熵，定义为 $H(X) = \sum_{i=1}^n p_i \log \frac{1}{p_i} = -\sum_{i=1}^n p_i \log p_i$

复习一下概率论

1. 联合概率分布，假设X和Y的取值个数分别为n和m，则其联合概率分布为：

$$p_{ij} = P(X = x_i, Y = y_j) = \frac{N_{ij}}{N} \quad (\text{其中} N \text{表示总样本数, } N_{ij} \text{表示} X = x_i \text{且} Y = y_j \text{的样本数目})$$

2. 类似的，边缘概率分布为：

$$p_{i.} = P(X = x_i) = \sum_{j=1}^m p_{ij} = \frac{N_{i.}}{N}$$

$$p_i = P(X = x_i) \quad i=1, 2, \dots, n$$

$$-\sum_{j=1}^m P(y_j | x_i) \log P(y_j | x_i)$$

因此，定义给定X的条件下Y的条件熵为

$$H(Y | X) = \sum_{i=1}^n p_i H(Y | X = x_i)$$



特征选择——信息增益 (Information Gain)

X的熵: $H(X) = \sum_{i=1}^n p_i \log \frac{1}{p_i} = - \sum_{i=1}^n p_i \log p_i$

条件熵: $H(Y|X) = - \sum_{i=1}^n P(x_i) \sum_{j=1}^m P(y_j|x_i) \log P(y_j|x_i)$

信息增益代表了在一个条件下，信息复杂度（不确定性）减少的程度。它的

计算方法为：信息增益 = 熵 - 条件熵

$$InfoGain = H(D) - H(D|A^i)$$

D为样本集合, 设 A^i 为数据集中任一属性变量



特征选择——信息增益 (Information Gain)

X的熵: $H(X) = \sum_{i=1}^n p_i \log \frac{1}{p_i} = -\sum_{i=1}^n p_i \log p_i$

条件熵: $H(Y|X) = -\sum_{i=1}^n P(x_i) \sum_{j=1}^m P(y_j|x_i) \log P(y_j|x_i)$

信息增益代表了一个条件下，信息复杂度（不确定性）减少的程度。它的计算方法为：信息增益 = 熵 - 条件熵

$$InfoGain = H(D) - H(D|A^i) = H(D) - \sum_{j=1}^J \frac{|D^j|}{|D|} H(D^j)$$

D为样本集合，设 A^i 为数据集中任一属性变量， D^j 表示属性 A^i 取值为 a^{ij} 时的样本子集。

信息增益用于构建ID3决策树

依次计算各个属性的信息增益然后选择最大的那个属性来划分分支



特征选择——信息增益

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	是否好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.46	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.36	0.37	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

如何计算各个属性的信息增益？

特征选择——信息增益

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	是否好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.46	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.36	0.37	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

以色泽属性为例，有三种取值，为{青绿、乌黑、浅白}。对其进行划分可得到三个子集 D^1 ， D^2 ， D^3 。

D^1 包含6个样本，正反例分别为 $\frac{3}{6}$ 、 $\frac{3}{6}$ ； D^2 包含6个样本，正反例分别为 $\frac{4}{6}$ 、 $\frac{2}{6}$ ； D^3 包含5个样本，正反例分别为 $\frac{1}{5}$ 、 $\frac{4}{5}$ 。



特征选择——信息增益

D^1 包含6个样本，正反例分别为 $\frac{3}{6}$ 、 $\frac{3}{6}$ ； D^2 包含6个样本，正反例分别为 $\frac{4}{6}$ 、 $\frac{2}{6}$ ； D^3 包含5个样本，正反例分别为 $\frac{1}{5}$ 、 $\frac{4}{5}$ 。各分支的信息熵可计算得：

$$H(D^1) = -\left(\frac{3}{6}\log_2\frac{3}{6} + \frac{3}{6}\log_2\frac{3}{6}\right) = 1.000$$

$$H(D^2) = -\left(\frac{4}{6}\log_2\frac{4}{6} + \frac{2}{6}\log_2\frac{2}{6}\right) = 0.918$$

$$H(D^3) = -\left(\frac{1}{5}\log_2\frac{1}{5} + \frac{4}{5}\log_2\frac{4}{5}\right) = 0.722$$

先前已求得瓜好坏的信息熵，根据信息增益公式，可计算出色泽的信息增益为：

$$InfoGain = H(D) - \sum_{j=1}^J \frac{|D^j|}{|D|} H(D^j)$$

$$InfoGain(D, \text{色泽}) = 0.9975 - \left(\frac{6}{17} * 1.000 + \frac{6}{17} * 0.918 + \frac{5}{17} * 0.722\right) = 0.108$$



特征选择——信息增益

类似的，我们可以计算其他属性的信息增益：

$$\text{InfoGain}(D, \text{根蒂}) = 0.143$$


$$\text{InfoGain}(D, \text{敲声}) = 0.141$$

$$\text{InfoGain}(D, \text{纹理}) = 0.381$$

$$\text{InfoGain}(D, \text{脐部}) = 0.289$$

$$\text{InfoGain}(D, \text{触感}) = 0.006$$

显然，纹理属性增益最大，于是它被选为划分属性



然后，再对每个分支的节点进一步划分。以纹理=“清晰”为例，该节点包含 D^1 中9个样本，可用属性集合为{色泽，根蒂、敲声、脐部、触感}。基于 D^1 计算各属性信息增益，如 $\text{InfoGain}(D^1, \text{根蒂})$ 。



特征选择——信息增益比 (Information Gain Ratio)

X的熵: $H(X) = \sum_{i=1}^n p_i \log \frac{1}{p_i} = - \sum_{i=1}^n p_i \log p_i$

条件熵: $H(Y|X) = - \sum_{i=1}^n P(x_i) \sum_{j=1}^m P(y_j|x_i) \log P(y_j|x_i)$

信息增益: $InfoGain = H(D) - H(D|A^i)$

存在问题: 以信息增益作为划分训练数据集的特征, 存在偏向于选择取值较多的特征的问题

解决方法——信息增益比 (Information Gain Ratio)



特征选择——信息增益比 (Information Gain Ratio)

X的熵: $H(X) = \sum_{i=1}^n p_i \log \frac{1}{p_i} = - \sum_{i=1}^n p_i \log p_i$

条件熵: $H(Y|X) = - \sum_{i=1}^n P(x_i) \sum_{j=1}^m P(y_j|x_i) \log P(y_j|x_i)$

信息增益: $InfoGain = H(D) - H(D|A^i)$

信息增益比: (Information Gain Ratio)

特征A对训练数据集D的信息增益比定义为其信息增益与训练数据集D关于特征A的值的熵之比。

$$G_r(D, A^i) = \frac{H(D) - H(D|A^i)}{H_{A^i}(D)}$$

$$H_{A^i}(D) = - \sum_{j=1}^J \frac{|D^j|}{|D|} \log \frac{|D^j|}{|D|}$$



特征选择——信息增益比 (Information Gain Ratio)

X的熵: $H(X) = \sum_{i=1}^n p_i \log \frac{1}{p_i} = - \sum_{i=1}^n p_i \log p_i$

条件熵: $H(Y|X) = - \sum_{i=1}^n P(x_i) \sum_{j=1}^m P(y_j|x_i) \log P(y_j|x_i)$

信息增益: $InfoGain = H(D) - H(D|A^i)$

信息增益比: (Information Gain Ratio)

特征A对训练数据集D的信息增益比定义为其信息增益与训练数据集D关于特征A的值的熵之比。

$$G_r(D, A^i) = \frac{H(D) - H(D|A^i)}{H_{A^i}(D)}$$

信息增益比用于构建C4.5决策树

先用信息增益选出一些高于平均水平的属性候选集，再从候选集中选出信息增益比最高的属性



CART

C4.5是ID3的升级版

CART决策树——更为高效的算法（二叉树）

用**基尼系数**（Gini Index）来进行特征选择



CART

基尼系数

给定数据集D，其中共有K个类别，用频率代替概率，数据集的概率分布为

$$p_i = \frac{|D_i|}{|D|}, i = 1, 2, \dots, K$$

对于数据分布p或者数据集D，其基尼系数定义为：

$$\text{Gini}(p) = \text{Gini}(D) = \sum_{i=1}^K \sum_{j=1}^K p_i p_j I\{j \neq i\} = \sum_{i=1}^K p_i (1 - p_i) = 1 - \sum_{i=1}^K p_i^2$$

基尼系数反映了随机抽取两个样本，其类别不一致的概率



CART

基尼系数

给定数据集D，其中共有K个类别，用频率代替概率，数据集的概率分布为

$$p_i = \frac{|D_i|}{|D|}, i = 1, 2, \dots, K$$

对于数据分布p或者数据集D，其基尼系数定义为：

$$\text{Gini}(p) = \text{Gini}(D) = \sum_{i=1}^K \sum_{j=1}^K p_i p_j I\{j \neq i\} = \sum_{i=1}^K p_i (1 - p_i) = 1 - \sum_{i=1}^K p_i^2$$

对于样本D，根据特征A=a，把D分为D1和D2两类，则在特征A的条件下，D的基尼系数表示为：

$$\text{Gini}(D, A) = \frac{|D_1|}{|D|} \text{Gini}(D_1) + \frac{|D_2|}{|D|} \text{Gini}(D_2)$$

选择能够使样本集合划分后基尼指数**最小**的属性进行子树生成



决策树剪枝 (Pruning)

为什么要剪枝？——防止过拟合

根据剪枝操作触发时间的不同，可以将它们分成两种，一种称为预剪枝，另一种称为后剪枝。



决策树剪枝 (Pruning)

预剪枝 (Pre-Pruning)

在特征选择时做剪枝操作

通过验证集进行判断当前选择的划分能否提升模型的准确率

能——进行划分


不能——当前节点作为叶节点，并以当前节点最多样本类别

作为预测值



决策树剪枝 (Pruning)

预剪枝例子



决策树剪枝 (Pruning)

预剪枝 (Pre-Pruning)

- 优点

- 降低过拟合风险，显著减少训练时间和测试时间开销。

- 缺点

- 欠拟合风险：有些分支的当前划分虽然不能提升泛化性能，但在其基础上进行的后续划分却有可能显著提高性能。预剪枝基于“贪心”本质禁止这些分支展开，带来了欠拟合风险。



决策树剪枝 (Pruning)

后剪枝 (Post-Pruning)

简单地说，后剪枝是先从训练集生成一颗完整的决策树，然后在进行剪枝处理。



决策树剪枝 (Pruning)

后剪枝 (Post-Pruning)

简单地说，后剪枝是先从训练集生成一颗完整的决策树，然后在进行剪枝处理。

后剪枝裁剪的评判标准很多，如错误率降低剪枝 (REP)、悲观剪枝 (BEP)、代价复杂度剪枝 (CCP) 等。



决策树剪枝 (Pruning)

后剪枝 (Post-Pruning)

今天介绍一种常用的，依据代价函数（损失函数）来进行后剪枝操作。

对于一棵树，其损失函数定义为**经验损失**和**结构损失**两个部分：经验损失是指模型是对模型性能的度量，结构损失是对模型复杂度的度量。

损失函数：

$$J(T) = \sum_{i=1}^M N_i H_i(T) + \lambda |T|$$




决策树剪枝 (Pruning)

后剪枝 (Post-Pruning)

对于一棵树，其损失函数定义为**经验损失**和**结构损失**两个部分：经验损失是指模型是对模型**性能的度量**，结构损失是对模型**复杂度的度量**。

损失函数：

$$J(T) = \sum_{i=1}^M N_i H_i(T) + \lambda |T|$$


T叶节点的数目为M。其中 N_i 为第 i 个叶节点中样本的数目， $H_i(T)$ 为对应节点上的熵。



决策树剪枝 (Pruning)

后剪枝 (Post-Pruning)

自底向上剪枝的过程中，对所有子节点均为叶节点的子树，如果将某个子树进行剪枝后能够使得损失函数变小且在所有子树中最小，则将该子树剪去，然后重复这个剪枝过程直到代价函数不再变小为止。


$$J(T) = \sum_{i=1}^M N_i H_i(T) + \lambda |T|$$

上升 降低




决策树剪枝 (Pruning)

后剪枝例子



决策树剪枝 (Pruning)

后剪枝例子



假设左边子树符合裁剪条件，减去左边子树，用叶子节点代替，叶子节点的分类以剩余样本类别最多为标准。假设10个好瓜，30个坏瓜，则新增叶子节点为坏瓜



小结

1. 算法概述
2. 特征选择（熵、条件熵、信息增益、信息增益比）
3. CART（基尼系数）
4. 决策树剪枝（前剪枝、后剪枝）



谢谢！

