



福建師範大學
FUJIAN NORMAL UNIVERSITY

《机器学习》

【第五章-支持向量机】

黄锐泓

本节要点


1. 基本概念
2. 线性可分支持向量机
3. 线性支持向量机
4. 合页损失函数
5. 核技巧
6. 二分类问题与多分类问题



基本概念

线性分类器回顾：


-> 在样本空间中寻找一个超平面，将不同类别的样本分开



基本概念


思考：将训练样本分开的超平面可能有很多，哪一个更好呢？

→ “**正中间**”的：鲁棒性最好，泛化能力最强



基本概念

支持向量机的优化目标：找到这样的超平面，使得空间中距离超平面最近的点到超平面的“间隔”尽可能大，这些点称为“支持向量”



基本概念

给定样本集合 $D = (\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_m, y_m)$, 设 $y_i \in \{-1, +1\}$

输入空间中的一个超平面表示为 $\vec{\omega}^T \vec{x} + b = 0$

空间中一点 $\vec{x}_i$ 到超平面 $\vec{\omega}^T \vec{x} + b = 0$ 的欧式距离为: $r_i = \frac{|\vec{\omega}^T \vec{x}_i + b|}{\|\vec{\omega}\|}$



基本概念

给定样本集合 $D = (\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_m, y_m)$, 设 $y_i \in \{-1, +1\}$

输入空间中的一个超平面表示为 $\vec{\omega}^T \vec{x} + b = 0$

空间中一点 $\vec{x}_i$ 到超平面 $\vec{\omega}^T \vec{x} + b = 0$ 的欧式距离为: $r_i = \frac{|\vec{\omega}^T \vec{x}_i + b|}{\|\vec{\omega}\|}$

如果超平面能正确将所有样本点分类, 则点到直线的距离可以写成分

段函数的形式:

$$r_i = \begin{cases} \frac{\vec{\omega}^T \vec{x}_i + b}{\|\vec{\omega}\|}, & y_i = +1 \\ -\frac{\vec{\omega}^T \vec{x}_i + b}{\|\vec{\omega}\|}, & y_i = -1 \end{cases}$$

上式也可用一个方程来表示 $r_i = \frac{\vec{\omega}^T \vec{x}_i + b}{\|\vec{\omega}\|} y_i$



线性可分支持向量机

线性可分支持向量机的目标是，通过求解 $\vec{\omega}$ 和 b 找到一个超平面 $\vec{\omega}^T \vec{x} + b = 0$ 。在保证超平面能够正确将样本进行分类的同时，使得距离超平面最近的点到超平面的距离尽可能大。

将距离超平面最近的点与超平面之间的距离记为 $r = \min_{i=1,2,\dots,m} r_i$

最优化问题可写做：

$$\begin{aligned} \max_{\vec{\omega}, b} \quad & r \\ \text{s. t.} \quad & r_i = \frac{\vec{\omega}^T \vec{x}_i + b}{\|\vec{\omega}\|} y_i \geq r, \quad i = 1, 2, \dots, m \end{aligned}$$



线性可分支持向量机

对于超平面 $\vec{\omega}^T \vec{x} + b = 0$ ，可以为等式两边同时乘以相同的非0的实数，超平面不发生变化。所以对任一支持向量 $\vec{x}^*$ 可以通过对超平面公式进行缩放使得

$(\vec{\omega}^T \vec{x}^* + b)y^* = 1$ ， $\vec{x}^*$ 到超平面的距离可表示为 $\frac{1}{\|\vec{\omega}\|}$ ，则优化问题可写作：


$$\begin{aligned} \max_{\vec{\omega}, b} \quad & \frac{1}{\|\vec{\omega}\|} \\ \text{s.t.} \quad & r_i = \frac{\vec{\omega}^T \vec{x}_i + b}{\|\vec{\omega}\|} y_i \geq \frac{1}{\|\vec{\omega}\|}, \quad i = 1, 2, \dots, m \end{aligned}$$

最大化 $\frac{1}{\|\vec{\omega}\|}$ 也即最小化 $\frac{1}{2} \|\vec{\omega}\|^2$ ，使用 $\frac{1}{2} \|\vec{\omega}\|^2$ 作为优化目标是为了计算方便：

$$\begin{aligned} \min_{\vec{\omega}, b} \quad & \frac{1}{2} \|\vec{\omega}\|^2 \\ \text{s.t.} \quad & r_i = (\vec{\omega}^T \vec{x}_i + b)y_i - 1 \geq 0, \quad i = 1, 2, \dots, m \end{aligned}$$



线性可分支持向量机



支持向量机的超平面存在唯一性，支持向量机中的支持向量至少为两个，由超平面分割成的正负两个区域至少各存在一个支持向量，且超平面的位置仅由这些支持向量决定，与支持向量外的其他样本点无关。在这两个区域，过支持向量，可以分别做一个与支持向量机分割超平面平行的平面 H_1 和 H_2 ，两个超平面之间的距离为 $\frac{2}{\|\bar{w}\|}$ 。



线性可分支支持向量机

拉格朗日乘子法简要介绍:

对于优化问题: $\min f(x)$

$$\text{s.t. } c_i(x) \leq 0, \quad i = 1, 2, \dots, m$$

定义拉格朗日函数: $Lag(\vec{x}, \vec{\lambda}) = f(x) + \sum_i \lambda_i c_i(x)$

通过求解对偶问题 $g(\lambda) = \inf Lag(\vec{x}, \vec{\lambda})$ 得到原始问题的最优解

对偶问题为: $\max g(\lambda) = \max \inf Lag(\vec{x}, \vec{\lambda})$
 $\text{s.t. } \lambda_i(x) \geq 0, \quad i = 1, 2, \dots, m$

x^* 和 λ^* 分别是原问题和对偶问题的解的充要条件是满足KKT条件:

$$\nabla_x Lag(x^*, \lambda^*) = 0, \quad \lambda_i c_i(x^*) = 0, \quad c_i(x^*) \leq 0, \quad \lambda_i \geq 0$$



线性可分支持向量机

对于优化问题

$$\begin{aligned} \min_{\vec{\omega}, b} \quad & \frac{1}{2} \|\vec{\omega}\|^2 \\ \text{s.t.} \quad & r_i = (\vec{\omega}^T \vec{x}_i + b)y_i - 1 \geq 0, \quad i = 1, 2, \dots, m \end{aligned}$$

可使用拉格朗日乘子法进行求解，拉格朗日函数为：

$$Lag(\vec{\omega}, b, \vec{\alpha}) = \frac{1}{2} \|\vec{\omega}\|^2 + \sum_{i=1}^m \alpha_i (1 - (\vec{\omega}^T \vec{x}_i + b)y_i)$$

其中， $\vec{\alpha} = (\alpha_1, \alpha_2, \dots, \alpha_m)$, $\alpha_i \geq 0$ 表示拉格朗日乘子。令 Lag 对 $\vec{\omega}$ 和 b 的偏导为0：

$$\begin{aligned} \frac{\partial Lag(\vec{\omega}, b, \vec{\alpha})}{\partial \vec{\omega}} &= \vec{\omega} - \sum_{i=1}^m \alpha_i y_i \vec{x}_i = 0 \\ \frac{\partial Lag(\vec{\omega}, b, \vec{\alpha})}{\partial b} &= - \sum_{i=1}^m \alpha_i y_i = 0 \end{aligned} \quad \xrightarrow{\text{解得}} \quad \begin{aligned} \vec{\omega} &= \sum_{i=1}^m \alpha_i y_i \vec{x}_i \\ 0 &= \sum_{i=1}^m \alpha_i y_i \end{aligned}$$



线性可分支持向量机

将 $\vec{\omega} = \sum_{i=1}^m \alpha_i y_i \vec{x}_i$ 代入原式 $Lag(\vec{\omega}, b, \vec{\alpha}) = \frac{1}{2} \|\vec{\omega}\|^2 + \sum_{i=1}^m \alpha_i (1 - (\vec{\omega}^T \vec{x}_i + b) y_i)$

$$0 = \sum_{i=1}^m \alpha_i y_i$$

可得到:

$$\begin{aligned} \min_{\vec{\omega}, b} Lag(\vec{\omega}, b, \vec{\alpha}) &= \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \vec{x}_i^T \vec{x}_j + \sum_{i=1}^m \alpha_i - \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \vec{x}_i^T \vec{x}_j - b \sum_{i=1}^m \alpha_i y_i \\ &= \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \vec{x}_i^T \vec{x}_j \end{aligned}$$

为0



线性可分支持向量机

对于式

$$\min_{\vec{\omega}, b} \text{Lag}(\vec{\omega}, b, \vec{\alpha}) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \vec{x}_i^T \vec{x}_j$$

求 $\min_{\vec{\omega}, b} \text{Lag}(\vec{\omega}, b, \vec{\alpha})$ 对 $\vec{\alpha}$ 的极大, 等价于求 $-\min_{\vec{\omega}, b} \text{Lag}(\vec{\omega}, b, \vec{\alpha})$ 对 $\vec{\alpha}$ 的极小, 因此原式

的对偶问题为:

$$\min_{\vec{\alpha}} \quad \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \vec{x}_i^T \vec{x}_j - \sum_{i=1}^m \alpha_i$$

$$\text{s. t.} \quad \sum_{i=1}^m \alpha_i y_i = 0$$

$$\alpha_i \geq 0, \quad i = 1, 2, \dots, m$$



线性可分支支持向量机

求解对偶问题的优化问题，即可得到： $\vec{\alpha}^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_m^*)$ ，根据KKT (Karush-Kuhn-Tucker) 条件， $(\vec{\omega}^*, b^*)$ 是原始问题的最优解，且 $\vec{\alpha}^*$ 是对偶问题的最优解的充要条件是： $(\vec{\omega}^*, b^*, \vec{\alpha}^*)$ 满足KKT条件，即：

$$\begin{cases} \alpha_i^* \geq 0, & i = 1, 2, \dots, m \\ (\vec{\omega}^{*T} \vec{x}_i + b^*) y_i - 1 \geq 0, & i = 1, 2, \dots, m \\ \alpha_i^* ((\vec{\omega}^{*T} \vec{x}_i + b^*) y_i - 1) = 0, & i = 1, 2, \dots, m \end{cases}$$

考察KKT条件的第三条，可以发现必有 $\alpha_i^* = 0$ 或 $(\vec{\omega}^{*T} \vec{x}_i + b^*) y_i - 1 = 0$

当 $\alpha_i^* > 0$ 时，有 $(\vec{\omega}^{*T} \vec{x}_i + b^*) y_i - 1 = 0$ ，说明样本 $(\vec{x}_i, y_i)$ 位于 H_1 或 H_2 上，

结合 $\vec{\omega}^* = \sum_{k=1}^m \alpha_k^* y_k \vec{x}_k$ 可以得到 $b^* = y_i - \sum_{k=1}^m \alpha_k^* y_k \vec{x}_k^T \vec{x}_i$,

由此得到分割超平面 $\vec{\omega}^{*T} \vec{x} + b^* = 0$



线性可分支持向量机

当 $\alpha_i^* = 0$ 时, $\vec{\omega}^* = \sum_{i=1}^m \alpha_i^* y_i \vec{x}_i$ 以及 $b^* = y_j - \sum_{i=1}^m \alpha_i^* y_i \vec{x}_i^T \vec{x}_j$ 均与样本 $(\vec{x}_i, y_i)$ 无关, 也就是说, 只有 $\alpha_i^* > 0$ 时, 样本 $(\vec{x}_i, y_i)$ 才对最终的结果产生影响, 此时样本的输入即为支持向量。求得支持向量机的参数后, 可根据下式判断任意样本的类型:

$$f(\vec{x}) = \text{sgn}(\vec{\omega}^{*T} \vec{x} + b^*)$$




线性支持向量机

线性可分支持向量机：假设样本空间中的样本能够通过一个超平面分隔开来。

但是生产环境中，我们获取到的数据往往存在噪声（正类中混入少量的负类样本，负类中混入少量的正类样本），从而使得数据变得线性不可分。

另一方面，即使样本集合线性可分，线性可分支持向量机给出的 H_1 和 H_2 之间的距离可能非常小。这种情况一般意味着模型的泛化能力降低，也就是产生了过拟合。因此我们希望 H_1 和 H_2 的距离尽可能大，这时同样可以使用线性支持向量机来允许部分样本点越过 H_1 和 H_2 。

→ 允许在一些样本上不满足约束



线性支持向量机

线性支持向量机在线性可分向量机的基础上引入了松弛变量 $\xi_i \geq 0$ 。对于样本点 $(\vec{x}_i, y_i)$ ，线性支持向量机允许部分样本落入越过超平面 H_1 或 H_2

线性可分支持向量机中，要求所有样本都满足 $(\vec{\omega}_i^T \vec{x}_i + b)y_i \geq 1$ ，此时 H_1 和 H_2

之间的距离 $\frac{2}{\|\vec{\omega}\|}$ 称为“硬间隔”。线性支持向量机中， $(\vec{\omega}^T \vec{x}_i + b)y_i \geq 1 - \xi_i$ 允

许部分样本越过超平面 H_1 或 H_2 ，此时 H_1 和 H_2 之间的距离 $\frac{2}{\|\vec{\omega}\|}$ 称为“软间隔”。

需要注意的是，此时的支持向量不再仅仅包含位于 H_1 和 H_2 超平面上的点，还可能包含其他点。



线性支持向量机

对线性支持向量机进行优化时，我们希望“软间隔”尽量大，同时希望越过超平面 H_1 和 H_2 的样本尽可能不要远离这两个超平面，则优化的目标函数可写为

$$\frac{1}{2} \|\vec{\omega}\|^2 + C \sum_{i=1}^m \xi_i$$

其中 C 为惩罚系数， $\frac{1}{2} \|\vec{\omega}\|^2$ 控制最小间隔尽可能的大，而 $\sum_{i=1}^m \xi_i$ 则控制越过超平面 H_1 或 H_2 的样本点离超平面尽量近， C 是对两者关系的权衡。线性支持向量机的优化问题可写为：

$$\begin{aligned} \min_{\vec{\omega}, b, \xi} \quad & \frac{1}{2} \|\vec{\omega}\|^2 + C \sum_{i=1}^m \xi_i \\ \text{s.t.} \quad & (\vec{\omega}^T \vec{x}_i + b)y_i \geq 1 - \xi_i, \quad i = 1, 2, \dots, m \\ & \xi_i \geq 0, \quad i = 1, 2, \dots, m \end{aligned}$$



线性支持向量机

类似于线性可分支持向量机中的求解过程，上式的拉格朗日函数可写作

$$Lag(\vec{\omega}, b, \vec{\xi}, \vec{\alpha}, \vec{\mu}) = \frac{1}{2} \|\vec{\omega}\|^2 + C \sum_{i=1}^m \xi_i + \sum_{i=1}^m \alpha_i (1 - \xi_i - (\vec{\omega}^T \vec{x}_i + b) y_i) - \sum_{i=1}^m \mu_i \xi_i$$

其中， $\vec{\alpha} = (\alpha_1, \alpha_2, \dots, \alpha_m), \alpha_i \geq 0$, $\vec{\mu} = (\mu_1, \mu_2, \dots, \mu_m), \mu_i \geq 0$ 是拉格朗日乘子，

令 Lag 对 $\vec{\omega}, b, \vec{\xi}$ 的导数为0，可解得：

$$\vec{\omega} = \sum_{i=1}^m \alpha_i y_i \vec{x}_i$$

$$0 = \sum_{i=1}^m \alpha_i y_i$$

$$0 = C - \alpha_i - \mu_i$$



线性支持向量机

将

$$\vec{\omega} = \sum_{i=1}^m \alpha_i y_i \vec{x}_i, \quad 0 = \sum_{i=1}^m \alpha_i y_i, \quad 0 = C - \alpha_i - \mu_i$$

代入原式

$$Lag(\vec{\omega}, b, \vec{\xi}, \vec{\alpha}, \vec{\mu}) = \frac{1}{2} \|\vec{\omega}\|^2 + C \sum_{i=1}^m \xi_i + \sum_{i=1}^m \alpha_i (1 - \xi_i - (\vec{\omega}^T \vec{x}_i + b) y_i) - \sum_{i=1}^m \mu_i \xi_i$$

可得到：

$$\begin{aligned} \min_{\vec{\omega}, b, \vec{\xi}} Lag(\vec{\omega}, b, \vec{\xi}, \vec{\alpha}, \vec{\mu}) &= \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \vec{x}_i^T \vec{x}_j + \sum_{i=1}^m \alpha_i - \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \vec{x}_i^T \vec{x}_j - b \sum_{i=1}^m \alpha_i y_i \\ &\quad + C \sum_{i=1}^m \xi_i - \sum_{i=1}^m \alpha_i \xi_i - \sum_{i=1}^m \mu_i \xi_i \\ &= \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \vec{x}_i^T \vec{x}_j \end{aligned}$$

为0



线性支持向量机

对于式
$$\min_{\vec{\omega}, b, \vec{\xi}} \text{Lag}(\vec{\omega}, b, \vec{\xi}, \vec{\alpha}, \vec{\mu}) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \vec{x}_i^T \vec{x}_j$$

求 $\min_{\vec{\omega}, b, \vec{\xi}} \text{Lag}(\vec{\omega}, b, \vec{\xi}, \vec{\alpha}, \vec{\mu})$ 对 $\vec{\alpha}, \vec{\mu}$ 的极大, 等价于求 $-\min_{\vec{\omega}, b, \vec{\xi}} \text{Lag}(\vec{\omega}, b, \vec{\xi}, \vec{\alpha}, \vec{\mu})$ 对 $\vec{\alpha}, \vec{\mu}$ 的极

小, 因此原式的对偶问题为:

$$\min_{\vec{\alpha}} \quad \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \vec{x}_i^T \vec{x}_j - \sum_{i=1}^m \alpha_i$$

$$s. t. \quad \sum_{i=1}^m \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, m$$



线性支持向量机

观察一下两式，可以发现，两者唯一的区别在于对 α_i 的约束条件的不同。线性支持向量机中是 $0 \leq \alpha_i \leq C$ ，而线性可分支支持向量机中是 $0 \leq \alpha_i$

$$\min_{\vec{\alpha}} \quad \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \vec{x}_i^T \vec{x}_j - \sum_{i=1}^m \alpha_i$$

$$s. t. \quad \sum_{i=1}^m \alpha_i y_i = 0$$

$$\alpha_i \geq 0, \quad i = 1, 2, \dots, m$$

线性可分支支持向量机

$$\min_{\vec{\alpha}} \quad \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \vec{x}_i^T \vec{x}_j - \sum_{i=1}^m \alpha_i$$

$$s. t. \quad \sum_{i=1}^m \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, m$$

线性支持向量机



线性支持向量机

求解上式中(对偶问题)的优化问题, 即可得到 $\vec{\alpha}^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_m^*)$ 。

根据KKT条件, $(\vec{\omega}^*, b^*, \vec{\xi}^*)$ 是原始问题式的最优解且 $\vec{\alpha}^*$ 是对偶问题式的最优解的充要条件是: $(\vec{\omega}^*, b^*), \vec{\alpha}^*$ 满足KKT条件, 即:

$$\begin{cases} \alpha_i^* \geq 0, & i = 1, 2, \dots, m \\ \mu_i^* \geq 0, & i = 1, 2, \dots, m \\ (\vec{\omega}^{*T} \vec{x}_i + b^*) y_i - 1 + \xi_i \geq 0, & i = 1, 2, \dots, m \\ \alpha_i^* ((\vec{\omega}^{*T} \vec{x}_i + b^*) y_i - 1 + \xi_i) = 0, & i = 1, 2, \dots, m \\ \xi_i \geq 0, & i = 1, 2, \dots, m \\ \mu_i \xi_i = 0, & i = 1, 2, \dots, m \end{cases}$$



线性支持向量机

类似线性可分支持向量机，可得

$$\vec{\omega}^* = \sum_{i=1}^m \alpha_i^* y_i \vec{x}_i$$
$$b^* = y_j - \sum_{i=1}^m \alpha_i^* y_i \vec{x}_i^T \vec{x}_j$$

由此得到分割超平面 $\vec{\omega}^{*T} \vec{x} + b^* = 0$

通过分析 α_i^* 的值，可以确定样本相对分割超平面的位置



线性支持向量机

当 $\alpha_i^* = 0$ 时，式与样本 $(\vec{x}_i, y_i)$ 无关。说明该样本对最终的结果不产生影响，位于软间隔外的正确区域。

当 $0 < \alpha_i^* < C$ 时，根据式有 $\mu_i > 0$ 。根据KKT条件中 $\mu_i \xi_i = 0$ 的约束，此时必有 $\xi_i = 0$ ，则 $(\vec{\omega}^{*T} \vec{x}_i + b^*) y_i = 1$ ，所以支持向量 $(\vec{x}_i, y_i)$ 在软间隔的边界上。

当 $\alpha_i = C$ 时，根据 $0 = C - \alpha_i - \mu_i$ 可以得到 $\mu_i = 0$ 及 $\xi_i \geq 0$ 。此时如果 $\xi_i \leq 1$ ，则 $(\vec{\omega}^{*T} \vec{x}_i + b^*) y_i = 1 - \xi_i \geq 0$ ，支持向量 $(\vec{x}_i, y_i)$ 能够被正确分类，位于分割超平面正确分类的一侧；如果 $\xi_i > 1$ ，则 $(\vec{\omega}^{*T} \vec{x}_i + b^*) y_i = 1 - \xi_i < 0$ ，支持向量 $(\vec{x}_i, y_i)$ 被错误分类，位于分割超平面错误分类的一侧。




线性支持向量机

与线性可分支持向量机不同，线性支持向量机的支持向量不一定在 H_1 或者 H_2 上，

求得支持向量机的参数后，即可根

据式 $f(\vec{x}) = \text{sgn}(\vec{\omega}^*{}^T \vec{x} + b^*)$ 判断任意样本的类别



合页损失函数 (Hinge Loss)

对于变量 x ，合页损失函数的定义为： $[x]_+ = \begin{cases} x & x > 0 \\ 0 & x \leq 0 \end{cases}$


对于线性支持向量机，以下左侧的最优化问题，等价于以下右侧优化式中的问题

$$\min_{\vec{\omega}, b, \xi} \frac{1}{2} \|\vec{\omega}\|^2 + C \sum_{i=1}^m \xi_i \quad \longleftrightarrow \quad \min_{\vec{\omega}, b} \sum_{i=1}^m [1 - (\vec{\omega}^T x_i + b)y_i]_+ + \lambda \|\vec{\omega}\|^2$$

$$s. t. \quad (\vec{\omega}^T \vec{x}_i + b)y_i \geq 1 - \xi_i, \quad i = 1, 2, \dots, m$$

$$\xi_i \geq 0, \quad i = 1, 2, \dots, m$$

其中， $[1 - (\vec{\omega}^T x_i + b)y_i]_+$ 是合页损失的形式



合页损失函数

$$\begin{aligned} \min_{\vec{\omega}, b, \xi} \quad & \frac{1}{2} \|\vec{\omega}\|^2 + C \sum_{i=1}^m \xi_i \\ \text{s.t.} \quad & (\vec{\omega}^T \vec{x}_i + b)y_i \geq 1 - \xi_i, \quad i = 1, 2, \dots, m \\ & \xi_i \geq 0, \quad i = 1, 2, \dots, m \end{aligned} \quad \longleftrightarrow \quad \min_{\vec{\omega}, b} \sum_{i=1}^m [1 - (\vec{\omega}^T x_i + b)y_i]_+ + \lambda \|\vec{\omega}\|^2$$

证明：令 $[1 - (\vec{\omega}^T x_i + b)y_i]_+ = \xi_i$ ，则：

$$\min_{\vec{\omega}, b} \sum_{i=1}^m [1 - (\vec{\omega}^T x_i + b)y_i]_+ + \lambda \|\vec{\omega}\|^2 \quad \longleftrightarrow \quad \min_{\vec{\omega}, b} \sum_{i=1}^m \xi_i + \lambda \|\vec{\omega}\|^2$$

再令 $\lambda = \frac{1}{2C}$ 则有：

$$\min_{\vec{\omega}, b} \frac{1}{C} \left(\frac{1}{2} \|\vec{\omega}\|^2 + C \sum_{i=1}^m \xi_i \right)$$

因此两式等价




核技巧

上面讨论的线性可分支持向量机和线性支持向量机都假设数据是线性可分的（线性支持向量机可以认为是为了解决线性可分样本集中的噪声问题）。

而实际场景中我们经常会遇到数据线性不可分的情况。此时，就可以通过本节介绍的**核方法**将输入空间线性不可分的数据转化为特征空间线性可分的数据，在特征空间求解支持向量机的超平面。



核技巧



假设样本集合能够被方程 $x_1^2 + x_2^2 - r^2 = 0$ 分为圆内和圆外两个部分，则可以通过一个映射函数

$$\phi(\vec{x}) = (x_1^2, \sqrt{2}x_1x_2, x_2^2) = (z_1, z_2, z_3)$$

将二维空间中的点 $\vec{x} = (x_1, x_2)$ 映射为另一种表示 (z_1, z_2, z_3) 。原来二维空间中的点线性不可分，但在三维空间新的表示下，样本集中的点可以通过平面 $z_1 + z_3 - r^2 = 0$ 区分开来，即样本点在特征空间线性可分。 (z_1, z_2, z_3) 所在的空间即为样本的特征空间。



核技巧

当输入空间 $\mathcal{X}$ 中的样本点线性不可分时，可以通过一个映射函数 $\vec{z} = \phi(\vec{x}): \mathcal{X} \rightarrow \mathcal{H}$ ，将样本集合映射到特征空间 $\mathcal{H}$ （也称为希尔伯特空间），使其线性可分。这样就可以在特征空间运行支持向量机算法，得到特征空间的一个分割超平面 $\vec{\omega}^{*T} \vec{z} + b^* = 0$ ，其中 $(\vec{\omega}^*, b^*)$ 为特征空间分割超平面的法向量和偏置。

以线性支持向量机为例，优化问题对应变为：

$$\begin{aligned} \min_{\vec{\alpha}} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(\vec{x}_i)^T \phi(\vec{x}_j) - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, m \end{aligned}$$

此时决策函数为： $f(\vec{x}) = \text{sgn}(\vec{\omega}_z^{*T} \vec{z} + b_z^*) = \text{sgn}(\vec{\omega}_z^{*T} \phi(\vec{x}) + b_z^*)$



核技巧

现实场景中，我们一般很难找到一个映射函数 $\phi(\vec{x})$ ，将样本从输入空间映射到特征空间，并使其在特征空间线性可分。为了避免这个问题，可以使用这样一个函数 $\kappa(\vec{x}_i, \vec{x}_j)$ 代替式中 $\phi(\vec{x}_i)^T \phi(\vec{x}_j)$ 的计算

$$\kappa(\vec{x}_i, \vec{x}_j) = \phi(\vec{x}_i)^T \phi(\vec{x}_j)$$

其中 κ 为核函数。于是可以将上式中的优化问题重新写作：

$$\begin{aligned} \min_{\vec{\alpha}} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \kappa(\vec{x}_i, \vec{x}_j) - \sum_{i=1}^m \alpha_i \\ \text{s. t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, m \end{aligned}$$



核技巧

相应的决策函数为：

$$\begin{aligned} f(\vec{x}) &= \text{sgn}(\vec{\omega}^{*T} \phi(\vec{x}) + b^*) \\ &= \text{sgn}\left(\sum_{i=1}^N \alpha_i y_i \phi(\vec{x}_i)^T \phi(\vec{x}) + b^*\right) \\ &= \text{sgn}\left(\sum_{i=1}^N \alpha_i y_i \kappa(\vec{x}_i, \vec{x}) + b^*\right) \end{aligned}$$

实际应用中，我们并不关心 ϕ 是如何定义的，只要核函数 κ 在支持向量机模型中表现足够好即可。然而并不是任意函数 f 都能用作核函数，因为不一定存在这样的隐式映射函数 ϕ ，满足 $f(\vec{x}_i, \vec{x}_j) = \phi(\vec{x}_i)^T \phi(\vec{x}_j)$



核技巧

为了考察函数 f 是否可以用作核函数，定义核矩阵

$$K = \begin{pmatrix} f(\vec{x}_1, \vec{x}_1) & f(\vec{x}_1, \vec{x}_2) & \cdots & f(\vec{x}_1, \vec{x}_m) \\ f(\vec{x}_2, \vec{x}_1) & f(\vec{x}_2, \vec{x}_2) & \cdots & f(\vec{x}_2, \vec{x}_m) \\ \vdots & \vdots & \ddots & \vdots \\ f(\vec{x}_m, \vec{x}_1) & f(\vec{x}_m, \vec{x}_2) & \cdots & f(\vec{x}_m, \vec{x}_m) \end{pmatrix}$$

其中 $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_m$ 表示输入空间中的样本点集合。

可以证明，函数 f 是核函数当且仅当核矩阵 K 是对称半正定的。

能够在特征空间使得样本线性可分的核函数有无数个，具体哪个核函数对样本分类的效果最好需要根据实际情况选择 -> 模型选择



核技巧

常用的核函数有：

线性核函数 $\kappa(\vec{x}_i, \vec{x}_j) = \vec{x}_i^T \vec{x}_j$ ，即支持向量机中的形式

多项式核函数 $\kappa(\vec{x}_i, \vec{x}_j) = (\vec{x}_i^T \vec{x}_j)^p$ ， p 为超参数

高斯核函数 $\kappa(\vec{x}_i, \vec{x}_j) = \exp\left(-\frac{\|\vec{x}_i - \vec{x}_j\|^2}{2\sigma^2}\right)$ ， σ 为超参数。高斯核函数又被称为径向基（RBF）函数



二分类问题与多分类问题

如何将一个二分类算法扩展为多分类？

考虑 K 个类别 $C_1, C_2, \dots, C_K$ ，多分类学习的基本思路是“拆解法”，最经典的拆分策略有三种：


- 一对一（OvO）
- 一对多（OvM）
- 多对多（MvM）




二分类问题与多分类问题

一对一 (OvO)：将 K 个类别两两配对，一共可产生 $K(K-1)/2$ 个二分类任务。在测试阶段新样本将同时提交给所有的分类器，于是将得到 $K(K-1)/2$ 个分类结果，最终把预测最多的结果作为投票结果。

一对多 (OvM/OvR)：将每一个样例作为正例，其他剩余的样例作为反例来训练 K 个分类器，如果在测试时仅有一个分类器产生了正例，则最终的结果为该分类器，如果产生了多个正例，则判断分类器的置信度，选择置信度大的分类别标记作为最终分类结果。



二分类问题与多分类问题



OvM只需训练 K 个分类器，而OvO需训练 $K(K-1)/2$ 个分类器，因此，OvO的存储开销和测试时间开销通常比OvM更大。但在训练时，OvM每个分类器均使用全部测试样例，而OvO的每个分类器仅适用两个类的样例，因此，在类别很多时，OvO的训练时间开销通常比OvM更小。至于预测性能，则取决于具体的数据分布，在多数情形下两者差不多。




二分类问题与多分类问题

纠错输出码(ECOC)是多对多分类的一种常用的技术,分为编码和解码两个阶段。

在编码阶段,对 K 个类别进行 M 次划分,每次将一部分类划分为正类,一部分类划分为反类。编码矩阵有两种形式:二元码和三元码。前者只有正类和反类,后者还包括停用类。

在解码阶段,各分类器的预测结果联合起来形成测试示例的编码。该编码与各类所对应的编码进行比较,将距离最小的编码所对应的类别作为预测结果。



小结

1. 基本概念
2. 线性可分支持向量机
3. 线性支持向量机
4. 合页损失函数
5. 核技巧
6. 二分类问题与多分类问题



谢谢！

