



福建師範大學
FUJIAN NORMAL UNIVERSITY

《机器学习》

【第六章-降维算法】

黄锐泓



本节要点

1. 基本概念
2. 主成分分析
3. 奇异值分解



基本概念

为什么要进行数据降维？

- 去除冗余信息：减少存储空间和计算资源的开销，提高数据的分析效率
- 提高数据的可视化效果：将高维数据映射到低维空间中，从而便于对数据进行可视化，更好地理解 and 利用数据
- 提高数据的分析效果：帮助减少数据的维度，从而减少数据的复杂性，从而更容易发现数据的规律和特征，提高数据的分析效果
- 提高机器学习算法的性能：缓解“维数灾难”
- 降低模型的过拟合风险



基本概念

数据降维在数据分析中的应用：

- 图像处理：

- 对图像进行压缩和重构，从而减少存储空间和传输带宽

- 文本处理：

- 帮助减少文本的维度，去除冗余信息，提高文本的分类和聚类效果

- 生物信息学：

- 帮助用户对基因表达数据进行降噪和特征提取，从而提高基因表达数据的分析效果和可视化效果

-




基本概念

给定一个数据集: $D = \{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_m\}$

其中, $\vec{x}_i = (x_i^1, x_i^2, \dots, x_i^n)$, 当 n 非常大时, $\vec{x}_i$ 是一个高维的数据。

降维的目的就是降低数据的维度从而方便后续对数据的存储、可视化、建模等操作。



基本概念

给定一个数据集： $D = \{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_m\}$

其中， $\vec{x}_i = (x_i^1, x_i^2, \dots, x_i^n)$ ，当 n 非常大时， $\vec{x}_i$ 是一个高维的数据。

降维的目的就是降低数据的维度从而方便后续对数据的存储、可视化、建模等操作。

降维对数据的处理主要包含特征筛选和特征提取：

- 特征筛选：过滤掉数据中无用或冗余的特征
 - 例：相对于年龄，出生年月就是冗余特征
- 特征提取：对现有特征进行重新组合产生新的特征
 - 例：用质量特征除以体积特征就可以得到密度特征



基本概念

如果将**每个特征**看作是坐标系中的一个**轴**，降维的最终结果是将原始数据用**轴数更少**的新坐标系来表示，这样也方便了后续机器学习算法对数据建模。

生产实践中直接得到的数据往往需要首先进行降维处理，然后才会用机器学习算法进行数据建模分析。

常用降维方法有主成分分析、奇异值分解、线性判别分析、T-SNE等。





主成分分析

主成分分析（PCA）是一种经典的线性降维分析算法。

- 基本思想：通过**旋转坐标系**将数据在新的坐标系下表示，如果新的坐标系下某些轴包含的信息太少，则可以将其省略，从而达到降维的目的。
- 举例：
 - 如果二维空间中数据点的分布在一条直线周围，那么可以旋转坐标系，将x轴旋转到该直线的位置，此时每个数据点在y轴方向上的取值基本接近于零。此时，y方向上数据的方差极小，携带信息量极少，可以将y轴略去。这样就相当于在一维空间对数据进行了表示，也相当于将原始数据投影到了该直线上。



主成分分析



主成分分析

- 对于多维特征变量中的每个子变量，主成分分析使用样本集合中对应子变量上取值的**方差来表示该特征的重要程度**。
 - **方差越大**，特征的重要程度越大；方差越小，特征的重要程度越小
 - 直观上，方差越大，样本集合中的数据在该轴上的取值分散的越开，混乱度越大，携带信息量越大；反之分布越集中，混乱度越小，携带信息量越小。
- 例：
 - 前面的例子中，样本集合中的数据在旋转过后的新的y轴上的方差接近于0，几乎不携带任何信息量，故可将其省去，达到降维的目的。



主成分分析

对坐标系进行旋转后，数据的坐标可以用正交变换来描述。

假设：

- n维空间中的数据用特征变量 $\vec{x}$ 表示： $\vec{x} = \{x_1, x_2, \dots, x_n\}$
- 旋转后的新坐标系下的数据用特征变量 $\vec{y}$ 表示： $\vec{y} = \{y_1, y_2, \dots, y_n\}$
- 正交变换的矩阵： $A = (\vec{a}_1, \vec{a}_2, \dots, \vec{a}_n)$
- 矩阵A当中的向量是一组标准正交基，其正交变换过程可写为： $\vec{y} = A^T \vec{x}$
- 记特征变量的均值为 $\vec{\mu} = \{\mu_1, \mu_2, \dots, \mu_n\}$ ，协方差矩阵为 Σ 。



主成分分析

主成分分析是一个迭代求解的过程

首先求旋转过后新坐标系的第一个轴，**要求在新的坐标表示下，样本集合的数据在该轴上取值的方差尽可能大**。样本集合在该轴上的取值用随机变

量 y_1 表示， $y_1 = \vec{a}_1^T \vec{x}$

此时求解过程可描述为

$$\max_{\vec{a}_1} \quad \text{var}(y_1) = \vec{a}_1^T \Sigma \vec{a}_1$$

$$s. t. \quad \vec{a}_1^T \vec{a}_1 = 1$$



主成分分析

求解该问题可使用拉格朗日乘子法，拉格朗日函数为：

$$Lag(\vec{a}_1) = \vec{a}_1^T \Sigma \vec{a}_1 - \lambda_1 (\vec{a}_1^T \vec{a}_1 - 1)$$

其中 λ_1 为拉格朗日乘子，令 $Lag(\vec{a}_1)$ 对 $\vec{a}_1$ 的导数为0可得：

$$\Sigma \vec{a}_1 = \lambda_1 \vec{a}_1$$

可以发现拉格朗日乘子 λ_1 为协方差矩阵 Σ 的特征值，而 $\vec{a}_1$ 则为对应的特征向量。则有： $\text{var}(y_1) = \vec{a}_1^T \Sigma \vec{a}_1 = \vec{a}_1^T \lambda_1 \vec{a}_1 = \lambda_1 \vec{a}_1^T \vec{a}_1 = \lambda_1$

求解 $\text{var}(y_1)$ 的最大就转化成了求 Σ 的最大特征值。

对 Σ 进行特征值分解，选择其中最大的特征值作为 λ_1 ，对应的特征向量即为要求解的 $\vec{a}_1$ ，这样就确定了第一个坐标轴，称 $y_1 = \vec{a}_1^T \vec{x}$ 为第一主成分。



主成分分析

接下来固定上述第一步确定下来的坐标轴，继续对坐标系进行旋转以确定第二个坐标轴。求解过程可描述为

$$\max_{\vec{a}_2} \text{var}(y_2) = \vec{a}_2^T \Sigma \vec{a}_2$$

$$\text{s.t.} \quad \vec{a}_1^T \vec{a}_2 = 0$$

$$\vec{a}_2^T \vec{a}_2 = 1$$

同样可以使用拉格朗日乘子法求解，拉格朗日函数为

$$\text{Lag}(\vec{a}_2) = \vec{a}_2^T \Sigma \vec{a}_2 - \lambda_2(\vec{a}_2^T \vec{a}_2 - 1) - \theta(\vec{a}_1^T \vec{a}_2 - 0)$$

令导数为0，可得： $2\Sigma\vec{a}_2 - 2\lambda_2\vec{a}_2 - \theta\vec{a}_1 = 0$

等式两边同时乘以 $\vec{a}_1^T$ 可得： $\theta = 0$ ，于是， $\Sigma\vec{a}_2 = \lambda_2\vec{a}_2$



主成分分析

由于

$$\Sigma \vec{a}_2 = \lambda_2 \vec{a}_2$$

可以发现拉格朗日乘子 λ_2 为协方差矩阵 Σ 的另一个特征值。则有：

$$\text{var}(y_2) = \vec{a}_2^T \Sigma \vec{a}_2 = \vec{a}_2^T \lambda_2 \vec{a}_2 = \lambda_2 \vec{a}_2^T \vec{a}_2 = \lambda_2$$

求解 $\text{var}(y_2)$ 的最大就转化成了求 Σ 的除 λ_1 之外的最大特征值。

对 Σ 进行特征值分解，选择**第二大**的特征值作为 λ_2 ，对应的特征向量即为要求解的 $\vec{a}_2$ ，这样就确定了第二个坐标轴，称 $y_2 = \vec{a}_2^T \vec{x}$ 为第二主成分。



主成分分析

以此类推直到所有的主成分 $\vec{y} = (\vec{a}_1^T \vec{x}, \vec{a}_2^T \vec{x}, \dots, \vec{a}_n^T \vec{x})$ 都被确定为止，可以发现 A 即为协方差矩阵对应的特征向量组，相应的特征值 $\lambda_1, \lambda_2, \dots, \lambda_n$ 即为新坐标系下每个轴上的方差，且 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$ 。

根据矩阵与其特征值之间的关系有：
$$\sum_{i=1}^n \lambda_i = \sum_{i=1}^n \sigma_{ii}^2$$

其中 σ_{ii}^2 为协方差矩阵 Σ 对角线上的元素，也即原始坐标系中第 i 个特征的方差。

可以发现将矩阵旋转后，方差的和未发生改变，也即信息量没发生改变，改变的是每个轴上携带信息量的大小，越重要的轴携带的信息量越大，反之越小。同时新坐标系下，特征之间线性无关。



主成分分析

生产实践中，数据的维度往往非常高，进行主成分分析后，特征值越小的主成分即方差越小的轴基本不携带任何信息，这样就可将特征值最小的几个主成分省略，只保留特征值较大的几个主成分。具体量化保留几个主成分往往根据实际情况通过计算**累计方差贡献率**来决定。这个过程其实就是将新坐标系中的样本投影到了一个低维的空间中。

方差 λ_i 的方差贡献率又称为**解释方差**（explained variance），定义为：

$$\epsilon_i = \frac{\lambda_i}{\sum_{j=1}^n \lambda_j}$$



主成分分析

累计方差贡献率为： $e_k = \sum_{i=1}^k \epsilon_i$

为累计方差贡献率设定一个阈值 t ，一般选择80%左右，

取前 k^* 个主成分作为则要保留的部分，使得：

$$e_k > t$$

这样就可以将正交矩阵压缩为 $A_{[1:k^*]} = (\vec{a}_1, \vec{a}_2, \dots, \vec{a}_{k^*})$ ，原始的数据用一个 n 维的向量 $\vec{x}$ 进行表示，在经过正交变换后，新的数据 $\vec{y} = A_{[1:k^*]}^T \vec{x}$ 用一个 k^* 维的向量表示，达到降维的目的。



主成分分析-方差的无偏估计

主成分分析的过程当中用到了总体的协方差矩阵 Σ ，生产实际中需要 we 根据样本集合对总体的方差进行估计。通常情况下用样本集合对总体的协方差矩阵进行估计时使用的是协方差矩阵的无偏估计量。

在概率统计中，设总体的均值和方差分别为

$$E(X) = \mu$$

$$\text{var}(X) = \sigma^2$$

设 $X_1, X_2, \dots, X_m$ 是来自总体的样本，则每个样本也是随机变量。每个样本之间独立同分布，且与整体具有相同的分布。对于整体，有

$$\sigma^2 = E[(X - EX)^2] = E[X^2 - 2XEX + (EX)^2] = E[X^2] - \mu^2$$

$$E[X_i^2] = E[X^2] = \mu^2 + \sigma^2$$



主成分分析-方差的无偏估计

使用统计量 $\bar{X} = \frac{1}{m} \sum_{i=1}^m X_i$:

$$E(\bar{X}) = E\left[\frac{1}{m} \sum_{i=1}^m X_i\right] = \frac{1}{m} \sum_{i=1}^m E[X_i] = \mu$$

称样本统计量 $\bar{X}$ 和 S^2 为总体均值和方差的 **无偏估计量**

使用统计量 $S^2 = \frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X})^2$:

$$\begin{aligned} E[S^2] &= \frac{1}{m-1} E\left[\sum_{i=1}^m (X_i - \bar{X})^2\right] = \frac{1}{m-1} E\left[\sum_{i=1}^m X_i^2 - m\bar{X}^2\right] = \frac{1}{m-1} E\left[\sum_{i=1}^m X_i^2 - \frac{1}{m} \sum_{i=1}^m \sum_{j=1}^m X_i X_j\right] \\ &= \frac{1}{m-1} E\left[\frac{m-1}{m} \sum_{i=1}^m X_i^2 - \frac{1}{m} \sum_{i=1}^m \sum_{j=1, j \neq i}^m X_i X_j\right] = \frac{1}{m-1} \left(\frac{m-1}{m} \sum_{i=1}^m E[X_i^2] - \frac{1}{m} \sum_{i=1}^m \sum_{j=1, j \neq i}^m E[X_i] E[X_j] \right) \\ &= \frac{1}{m-1} \left(\frac{m-1}{m} m(\mu^2 + \sigma^2) - \frac{m(m-1)}{m} \mu^2 \right) = \sigma^2 \end{aligned}$$



主成分分析-方差的无偏估计

将方差的估计量推广到主成分分析中，估计协方差矩阵 Σ 时有着类似的形式，记协方差矩阵中的元素为 s_{ij} ，则有：

$$s_{ij} = \frac{1}{n-1} \sum_{k=1}^n (x_{ik} - \bar{x}_i)(x_{jk} - \bar{x}_j)$$

此外，在主成分分析中，用于描述样本的多维特征向量中，每一维的量纲可能不同，这对方差的估计造成较大的影响，从而影响主成分分析的过程。所以，在进行主成分分析前，一般需要对样本集合中的所有数据在每一维特征进行规范化，即：

$$x_{ij} = \frac{x_{ij} - \mu_j}{\sqrt{\sigma_j^2}} = \frac{x_{ij} - \bar{x}_j}{S_j}$$



主成分分析-算法

输入：样本集合 $D = \{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_m\}$ ，其中 $\vec{x}_i = (x_{i1}, x_{i2}, \dots, x_{in})$ ； n 为描述每个样本的特征的个数；用于确定主成分个数的阈值 t

输出：样本集合的 k 个主成分表示

算法步骤：

1. 对样本集合进行规范化：

$$x_{ij} = \frac{x_{ij} - \mu_j}{\sqrt{\sigma_j^2}} = \frac{x_{ij} - \bar{x}_j}{S_j}$$



主成分分析-算法

2. 用规范化后的样本集合估计出特征变量的协方差矩阵 $\Sigma = \{S_{ij}\}_{m \times n}$

其中, $s_{ij} = \frac{1}{n-1} \sum_{k=1}^n (x_{ik} - \bar{x}_i)(x_{jk} - \bar{x}_j)$

3. 对协方差矩阵 Σ 进行特征值分解, 将特征值按照从大到小的顺序排序, 得到 n 个特征值 $\lambda_1, \lambda_2, \dots, \lambda_n$, 及对应的特征向量 $\vec{a}_1, \vec{a}_2, \dots, \vec{a}_n$

4. 根据 t , 计算累计方差贡献率, 确定要返回的特征向量的个数 k^* , 使得:

$$\sum_{i=1}^{k^*} \lambda_i / \sum_{j=1}^n \lambda_j \geq t$$


Return $\vec{Y} = A^T \vec{X}, A = (\vec{a}_1, \vec{a}_2, \dots, \vec{a}_{k^*})$ // 返回样本集合的 k^* 个主成分表示



主成分分析-鸢尾花数据降维


鸢尾花数据集中的每个样本有四个特征。对于四维数据，难以对其进行可视化，故使用PCA降维选择两个主成分将四维数据降低到二维，然后再进行数据可视化。

降维后的第一个主成分的方差贡献率为0.7296，第二个主成分的方差贡献率为0.2285。两者的累计方差贡献率为0.9581。如右图所示，只用第一个主成分和第二个主成分就能较好的在二维空间表示原始数据。




主成分分析-鸢尾花数据降维

为直观上理解主成分分析中坐标轴旋转的过程，只挑选出花瓣长度和花瓣宽度两个属性进行阐述。通过计算，第一主成分轴的方向为 $(\frac{\sqrt{2}}{2}, \frac{\sqrt{2}}{2})$ ，主成分分析相当于将原始坐标系绕原点逆时针旋转了45度后旋转到红色的坐标轴。



主成分分析-鸢尾花数据降维

将上图中红色坐标轴摆正，得到数据集的主成分表示，如下图所示。该坐标系中，第一主成分的贡献率为0.9814，第二主成分的贡献率为0.0186。可见第一主成分贡献了绝大部分信息。从下图中也可以看出，第一主成分上样本的取值分散程度要远大于第二个主成分。



奇异值分解

奇异值分解（Singular Value Decomposition, SVD）是一种机器学习中的常用算法，被广泛应用于数据降维、数据压缩等。奇异值分解是指，对于任意一个矩阵，我们都可以将其分解为三个矩阵乘积的形式。即：

$$A_{m \times n} = U \Sigma V^T$$

$U = (\vec{u}_1, \vec{u}_2, \dots, \vec{u}_m)$, $V = (\vec{v}_1, \vec{v}_2, \dots, \vec{v}_n)$: m 阶和 n 阶正交方阵

$\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_{\min(m,n)})$: $m \times n$ 的对角阵，且对角上的元素从大到小排列

U : 左奇异矩阵, V : 右奇异矩阵, Σ : 奇异值矩阵



奇异值分解

根据 A 可以构造一个实对称矩阵 $A^T A$, 且有 $\text{rank}(A^T A) = \text{rank}(A) = r$

对 $A^T A$ 进行特征值分解并按照从大到小的顺序对特征值进行排列可以得到 n 个单位特征值, 记为:

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > \lambda_{r+1} = \lambda_{r+1} = \cdots = \lambda_n = 0$$

其中包含 r 个非0的特征值, 以及 $n-r$ 个0特征值, 对应的单位特征向量记为:

$$V = \{\vec{v}_1, \vec{v}_2, \cdots, \vec{v}_r, \vec{v}_{r+1}, \cdots, \vec{v}_n\}$$

其中, 前 r 个单位特征向量固定, 后 $n-r$ 个特征向量可以是齐次线性方程组 $A^T A \vec{x} = 0$ 的任意单位基础解系。

可以证明: $\|A\vec{v}_i\|^2 = (A\vec{v}_i)^T (A\vec{v}_i) = \vec{v}_i^T A^T A \vec{v}_i = \vec{v}_i^T \lambda_i \vec{v}_i = \lambda_i \|\vec{v}_i\|^2 = \lambda_i$



奇异值分解

将 $A^T A \vec{v}_i = \lambda_i \vec{v}_i$ 等式两端同时乘以 A 得到 $AA^T(A\vec{v}_i) = \lambda_i(A\vec{v}_i)$ ，可以看到 λ_i 同时也是方阵 AA^T 的特征值，其对应的特征向量为 $A\vec{v}_i$ 。

记： $\sigma_i = \sqrt{\lambda_i}$ ， $\vec{u}_i = \frac{A\vec{v}_i}{|A\vec{v}_i|} = \frac{A\vec{v}_i}{\sigma_i}$ ， 则：

$$\begin{aligned} AV_r &= (A\vec{v}_1, A\vec{v}_2, \dots, A\vec{v}_r) \\ &= (\sigma_1 \vec{u}_1, \sigma_2 \vec{u}_2, \dots, \sigma_r \vec{u}_r) \\ &= U_r \Sigma_r \end{aligned}$$

其中 $U_r = \{\vec{u}_1, \vec{u}_2, \dots, \vec{u}_r\}$ ， $\Sigma_{r \times r} = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$

则有： $A = U_r \Sigma_r V_r^T$

这样就通过构造法构造了矩阵的一个奇异值分解。同时也间接证明了奇异值分解的存在性。 $U_r \Sigma_r V_r^T$ 又称为矩阵的满秩分解。



奇异值分解

若将 Σ 通过增加全 0 行或全 0 列的方式表示成 $m \times n$ 阶矩阵 $\Sigma_{m \times n}$ 的形式，并计算齐次线性方程组 $AA^T \vec{x} = 0$ 的任意一个单位基础解系，表示为 $U_{r+1:m} = \{\vec{u}_{r+1}, \vec{u}_{r+2}, \dots, \vec{u}_m\}$ ，计算齐次线性方程组 $A^T A \vec{x} = 0$ 的任意一个单位基础解系，表示为 $V_{r+1:n} = \{\vec{v}_{r+1}, \vec{v}_{r+2}, \dots, \vec{v}_n\}$ ，

令 $U_{m \times m} = (U_r, U_{r+1:m})$ ， $V_{n \times n} = (V_r, V_{r+1:n})$

$$\text{则有： } A = U \Sigma V = (U_r, U_{r+1:m}) \begin{pmatrix} \Sigma_r & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} V_r \\ V_{r+1:n} \end{pmatrix} = U_r \Sigma_r V_r^T$$

当矩阵 AA^T 或者 $A^T A$ 不是满秩矩阵时，由于 $AA^T \vec{x} = \lambda \vec{x} = \vec{0}$ 及 $A^T A \vec{x} = \vec{0}$ 存在多个基础解系，可以看出矩阵的奇异值分解可能有不止一种表示，当且仅当 AA^T 为满秩矩阵时，矩阵 A 的奇异值分解存在唯一解。



奇异值分解用于数据压缩

矩阵的F-范数：定义矩阵 $A_{m \times n}$ 的F-范数（Frobenius范数）为矩阵中所有元素的

平方和再开方： $\|A\|_F = (\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2)^{\frac{1}{2}}$

根据矩阵加法的性质，矩阵的奇异值分解还可以表示成如下形式：

$$A = U\Sigma V^T = \sum_{i=1}^r \sigma_i \vec{u}_i \vec{v}_i^T$$

任何一个矩阵都可以写成是若干个子矩阵加权求和的形式。

$$\|A\|_F^2 = (U\Sigma V^T)^2 = \left(\sum_{i=1}^r \sigma_i \vec{u}_i \vec{v}_i^T\right)^2 = \sum_{i=1}^r \sigma_i^2 \vec{u}_i \vec{v}_i^T \vec{v}_i \vec{u}_i^T = \sum_{i=1}^r \sigma_i^2$$



奇异值分解用于数据压缩

可以证明，从集合 $\{1, 2, \dots, r\}$ 中任选 k 个不同的元素 $\{p_1, p_2, \dots, p_k\}$ ，有

$$\text{rank}(\sum_{i=1}^k \sigma_{p_i} \vec{u}_{p_i} \vec{v}_{p_i}^T) = k,$$

记其前 j 项累加和为 B_j ，即：

$$B_j = \sum_{i=1}^j \sigma_i \vec{u}_i \vec{v}_i^T, \quad \text{rank}(B_j) = j$$

可以证明 B_j 是所有秩为 j 的矩阵中，能使 $A - B_j$ 的F-范数 $\|A - B_j\|_F$ 达到最小的，

即L2损失函数最小，且损失值为 $\sum_{i=j+1}^p \sigma_i^2$ 。据此，可以对矩阵在L2损失指导下进

行压缩，压缩后的矩阵是在L2损失为 $\sum_{i=j+1}^r \sigma_i \vec{u}_i \vec{v}_i^T$ 情况下的近似。可以参考主成

分分析中的累计方差贡献率，只保留最大的前 k 项，完成数据压缩。压缩后的数据

表示为 $A = U_k \Sigma_k V_k^T$ ，称为矩阵 A 的截断奇异值分解。



奇异值分解用于数据压缩

在进行数据压缩时，原始数据需要的存储空间记为 $s=m \times n$ 。压缩后需要的存储空间是存储三个矩阵需要的空间大小，记为

$$t = m \times k + k + n \times k$$

要想达到数据压缩的目的，需要满足 $t < s$ ，即 $k < \frac{mn}{m+n+1}$


实际应用中往往有 $k \ll m$ 使得该式成立。



奇异值分解用于数据压缩

Lenna图是计算机图形学中广为使用的示例图片

使用SVD对Lenna图进行压缩，可以看到当 $k \approx 100$ 时，就已经能够很好的表示原始图像。



(a) $k=1$



(b) $k=10$



(c) $k=20$



(d) $k=50$



(e) $k=100$



(f) $k=500$ (原图)



奇异值分解

SVD与PCA的关系：

实际上，如果将矩阵 $A_{m \times n}$ 看作是一个样本集合，其中的行看作特征随机变量，列看作每一个样本。当对数据集进行规范化后，矩阵 $A^T A$ 就是样本集合的协方差矩阵。这样，SVD分解后的右奇异矩阵就是PCA分析中的特征向量组成的矩阵。



奇异值分解-几何解释

在标准坐标系中：

$$\vec{x} = x_1\vec{e}_1 + x_2\vec{e}_2 + \cdots + x_n\vec{e}_n = \sum_{i=1}^n x_i \vec{e}_i = (\vec{e}_1, \vec{e}_2, \cdots, \vec{e}_n) \begin{pmatrix} x_1 & & & \\ & x_2 & & \\ & & \ddots & \\ & & & x_n \end{pmatrix}$$

对向量使用矩阵A进行线性变换得到向量： $\vec{z} = A\vec{x} = U\Sigma V^T \vec{x}$

由上一小节的PCA分析，式中 $V^T \vec{x}$ 表示旋转坐标系，将 $\vec{x}$ 转化为新坐标系下的表述的过程，记为 $\vec{y} = V^T \vec{x} = (y_1, y_2, \cdots, y_n)^T$ 。这样 $A\vec{x}$ 可以写做：

$$\vec{z} = A\vec{x} = U\Sigma V^T \vec{x} = U\Sigma \vec{y} = (\vec{u}_1, \vec{u}_2, \cdots, \vec{u}_r) \begin{pmatrix} \sigma_1 y_1 & & & \\ & \sigma_2 y_2 & & \\ & & \ddots & \\ & & & \sigma_r y_r \end{pmatrix}$$

可以发现 $(\sigma_1 y_1, \sigma_2 y_2, \cdots, \sigma_r y_r)$ 相当于是基 $U = (\vec{u}_1, \vec{u}_2, \cdots, \vec{u}_r)$ 下对向量z的描述。



奇异值分解-几何解释

所以 $\vec{z} = A\vec{x}$ 可以描述为，首先对 $\vec{x}$ 所在的坐标系进行旋转，并将 $\vec{x}$ 表示为新坐标系 U' 下的表示 $\vec{y}$ ，然后再将 y_i 沿新坐标系下的第 i 个轴 $\vec{u}_i'$ 伸缩为原来的 σ_i 倍。如果在原始坐标系 $E = (\vec{e}_1, \vec{e}_2, \dots, \vec{e}_n)$ 中，随机变量 $\vec{x}$ 分布在一个半径为 R 的超球面上，那么 $\vec{z}$ 将会是新坐标系 U 下的一个超椭圆，且第 i 个轴上的半径为 $R\sigma_i$ 。



小结

1. 基本概念
2. 主成分分析
3. 奇异值分解



谢谢！

