



福建師範大學
FUJIAN NORMAL UNIVERSITY

《机器学习》

【第七章-贝叶斯分类器】

黄锐泓

本节要点

1. 概述
2. 概率相关知识
3. 贝叶斯分类原理
4. 朴素贝叶斯分类器
5. 例题



概述

- 人们积累了天空出现乌云后发生下雨的大量经历，能够推断下雨的可能性，这是总结出的**朴素的可能性推理**。
- 中国的**二十四节气**与**对应的农耕活动**，也是总结的可能性推理思维。例如“春分”对应播种小麦的最佳时机。
- 在**数理思维**角度，上述可能性推理对应着**概率方法**。
- 将**概率推理**放入机器学习的框架，进行**类推启发式的创新**，带来新的机器学习方法——朴素贝叶斯分类方法。



概率相关知识

- 概率是随机事件发生的可能性大小。
- 概率的统计定义：
 - 在同一组条件下所进行大量重复试验时，如果事件A出现的频率总是在区间 $[0,1]$ 上的一个确定常数 p 附近摆动，并且稳定于 p ，则称 p 为事件A的统计概率，即 $P(A)=p$ 。



概率相关知识

- 条件概率表示A发生的条件下，B发生的概率，即

$$P(B|A) = \frac{P(AB)}{P(A)}$$

- 全概率公式将事件A的发生概率转化为不同情况下事件A发生概率的计算：

$$P(A) = \sum_{i=1}^n P(B_i)P(A|B_i)$$



概率相关知识

- 贝叶斯定理或贝叶斯公式

$$P(B_i|A) = \frac{P(B_i)P(A|B_i)}{P(A)} = \frac{P(B_i)P(A|B_i)}{\sum_{j=1}^n P(B_j)P(A|B_j)}$$

- 乘法公式将联合概率分解为一些条件概率的乘积：

$$P(AB) = P(A)P(B|A) = P(B)P(A|B)$$



贝叶斯分类原理

已知：样本{学生成绩,奖学金有无}的训练集 $D=\{(x_i, y_i)\}$

任务：建立一个符合训练集 D 的分类模型

学号	总评成绩	奖学金
1	91	有
2	80	无
3	87	无
4	61	无
5	75	无
6	95	有
7	98	有
8	64	无
9	72	无
10	85	无



贝叶斯分类原理

- **先验概率**，用 $P(Y)$ 表示：根据以往经验和分析得到的概率，可以**通过统计获得**，或者依据经验给出。 $P(y=\text{有})=0.3$
- **后验概率**，条件概率，用 $P(Y|X)$ 表示：根据观察到的样本修正之后的概率，它反映在获得数据 X 后 Y 成立的概率。 $P(y=\text{有}|x=95)=1.0$
- **联合概率**，用 $P(X,Y)$ 表示：联合概率是指在多元的概率分布中多个随机变量分别满足各自条件的概率。一种简单的理解是两个事件 X 与 Y 共同发生的概率。 $P(y=\text{有}, x=95)=0.1$

学号	总评成绩	奖学金
1	91	有
2	80	无
3	87	无
4	61	无
5	75	无
6	95	有
7	98	有
8	64	无
9	72	无
10	85	无



贝叶斯分类原理

- 贝叶斯分类模型
 - 从数据集 D 学习出一个分类模型 M ，即利用 D 构建一个贝叶斯分类模型（贝叶斯公式）如下：

$$P(Y|X) = \frac{P(Y)P(X|Y)}{P(X)}$$

- 上式中等号右边的分子也是联合概率 $P(X,Y)$ 。
- 预测新样本 x_j 的类别，就是使用模型 M 计算 x_j 归属每个类别的概率 $P(Y=c_k|X=x_j)$ ，选概率最大的类别。



朴素贝叶斯分类器

(1) 朴素贝叶斯分类方法的基本假设

- 朴素贝叶斯假设的**核心思想**是：在给定类别标签的条件下，假设样本集的所有特征之间**相互独立**。
- 朴素贝叶斯假设：类别 c_k 条件下，样本 $\mathbf{x}_i$ 的特征 $\{x_{ij}\}$ 之间**相互条件独立**，即样本向量 $\mathbf{x}_i=(x_{i1}, x_{i2}, \dots, x_{im})$ 的条件联合概率可以分解为各个特征值条件概率的连乘：

$$P(X = \mathbf{x}_i | Y = c_k) = \prod_{j=1}^m P(x_{ij} | Y = c_k)$$

- 使用这个假设的贝叶斯分类器称为**朴素贝叶斯分类器**（Naive Bayes classifier）。



朴素贝叶斯分类器

(2) 朴素贝叶斯分类模型的求解

- 利用数据集D求出贝叶斯分类模型，需要分别求出 $P(Y)$ 、 $P(X|Y)$ 和 $P(X)$ 。

$$P(Y|X) = \frac{P(Y)P(X|Y)}{P(X)}$$

- $P(Y)$ 的求解是利用数据集D统计各个类别的先验概率 $P(Y=c_k)$ ，其中 $k=1,2,\dots,K$ ，即每类样本数目占数据集样本总数的比例。未知时可用均匀分布 $P(Y=c_k)=1/K$ 。
- $P(X|Y)$ 的求解是利用数据集D，由朴素贝叶斯假设确立的样本的条件联合概率公式，统计计算 $P(X|Y=c_k)$ 。
- $P(X)$ 无需求解，因 $P(X)$ 与类别无关，可以省略。



朴素贝叶斯分类器

- 解出的 $P(Y|X)$ 公式，即朴素贝叶斯分类模型：

$$P(Y = c_k | X) = \frac{P(Y = c_k)P(X | Y = c_k)}{P(X)}$$

(3) 朴素贝叶斯分类器及其使用

- 选择最大后验概率的类别作为新样本 $\mathbf{x}_j$ 的类别：

$$y = \arg \max_{c_k} P(Y = c_k)P(X = \mathbf{x}_j | Y = c_k)$$

其中 $k=1,2,\dots,K$



特征数据的概率计算

(1) 特征数据是离散型

样本向量 $\mathbf{x}_i$ 的第 j 个分量（特征 x_{ij} ）是离散值

- 对每个类别 c_k ，统计在特征 $x_{.j}$ 上每个离散值 v_l 对应的样本数目占 c_k 类样本数的比例，即离散值的类条件概率：

$$P(x_{.j} = v_l | Y = c_k) = \frac{N_{v,ck}}{N_{ck}}$$

- 若上式分子为0，概率为0，导致分类器的计算出问题
- 拉普拉斯平滑处理：上式中分子加1，分母加离散取值个数 L ：

$$P(x_{.j} = v_l | Y = c_k) = \frac{N_{v,ck} + 1}{N_{ck} + L}$$



特征数据的概率计算

(2) 特征数据是连续型

样本向量 $\mathbf{x}_i$ 的第 j 个分量（特征 x_{ij} ）是连续值

- 离散化方法：

- 将连续型特征离散化，即将特征 $x_{\cdot j}$ 的值域划分为若干区间，转换成若干个离散值 v_l ，
- 统计 c_k 类样本落入 v_l 的划分区间的数量占 c_k 类样本数的比例，作为 $P(x_{\cdot j}=v_l \mid Y=c_k)$ 。



朴素贝叶斯分类器的特点

- 优点：
 - 具有坚实的理论基础，可用于多分类任务，分类效率稳定。
 - 对小规模数据表现优良，适合增量式训练，可以分批训练。
 - 对缺失数据不敏感。
- 缺点：
 - 实践中属性之间独立假设可能不满足，在属性个数比较多或者属性之间相关性较大时，分类效果不佳。
 - 需要知道先验概率，但很多时候不能获取而依靠假设，这可能导致分类效果不佳。
 - 由后验概率决定类别，分类决策存在一定的错误率。



例题：成绩分类问题

成绩分类问题

- 给定10位学生的成绩 x 及类别 y 的数据（即带标签数据）
- 求新成绩92的类别。

解题思路：

- 这些数据需要预处理为易用的数值，再使用数据构建一个朴素贝叶斯分类器

学号	数学成绩	类别
1001	78	合格
1002	78	合格
1003	98	优秀
1004	65	合格
1005	93	优秀
1006	60	合格
1007	96	优秀
1008	91	优秀
1009	80	优秀
1010	87	优秀



例题：成绩分类问题

1. 求解方法简述：

- 使用朴素贝叶斯分类方法进行求解，需要分别求解：
 - 从成绩数据估计出 $P(Y)$
 - 从成绩数据估计出 $P(X|Y)$
- 获得朴素贝叶斯分类器（省略 $P(X)$ ）：
 - $P(Y|X)=P(Y)P(X|Y)$
- 使用分类器预测新样本 x_j 的类别：
 - 对每个类别 c_k ，计算 $P(Y=c_k|X=x_j)$ ；输出概率最大的类别



例题：成绩分类问题

2. 数据预处理

- 类别文字转数值：1代表优秀，0代表合格
- 成绩按区间离散化：
 - 区间90-100、80-89、70-79、60-69，对应转为离散值9、8、7、6
- 预处理后构成右表的训练数据

学号	数学成绩	类别
1001	78	合格
1002	78	合格
1003	98	优秀
1004	65	合格
1005	93	优秀
1006	60	合格
1007	96	优秀
1008	91	优秀
1009	80	优秀
1010	87	优秀



X	Y
7	0
7	0
9	1
6	0
9	1
6	0
9	1
9	1
8	1
8	1



例题：成绩分类问题

3. 由训练数据构建朴素贝叶斯分类器

- 由训练数据求 $P(Y)$: $P(Y=1) = 6/10$, $P(Y=0) = 4/10$
- 由训练数据求 $P(X|Y)$: (4个离散值9、8、7、6)

采用拉普拉斯平滑处理，即分子加1，分母加4：

$$P(X=9|Y=1) = (4+1)/(6+4) = 0.5 \quad P(X=8|Y=1) = (2+1)/(6+4) = 0.3$$

$$P(X=7|Y=1) = (0+1)/(6+4) = 0.1 \quad P(X=6|Y=1) = (0+1)/(6+4) = 0.1$$

$$P(X=9|Y=0) = (0+1)/(4+4) = 0.125 \quad P(X=8|Y=0) = (0+1)/(4+4) = 0.125$$

$$P(X=7|Y=0) = (2+1)/(4+4) = 0.375 \quad P(X=6|Y=0) = (2+1)/(4+4) = 0.375$$



例题：成绩分类问题

3. 由训练数据构建朴素贝叶斯分类器

- 朴素贝叶斯分类器已准备就绪：

$$\begin{aligned}P(X,Y) &= P(Y)P(X|Y) \\ &= P(Y=1)P(X|Y=1) \cup P(Y=0)P(X|Y=0)\end{aligned}$$

- 该公式中的每项均被求出具体数值
- 该公式中的分母 $P(X)$ 被省略



例题：成绩分类问题

4. 使用分类器

- 分类器的使用：给分类器输入新样本 $\mathbf{x}$ ，输出其类别 y
- 新样本 $X=92$ ，离散化为 9 ；根据前文获取有关的概率值：

$$P(Y=1|X=9)=P(Y=1)P(X=9|Y=1) = 0.6*0.5 = 0.3$$

$$P(Y=0|X=9)=P(Y=0)P(X=9|Y=0) = 0.4*0.125 = 0.05$$

- $P(Y=1|X=9)$ 的概率更大，则新样本 92 的类别为 $Y=1$ （优秀）



文本数据的概率计算—初步理解

文本数据

- 先验概率：

- $P(\text{sport})$ 估计为 $3/5$
 - $P(\text{not})$ 估计为 $2/5$

文本	标签
he likes playing football	sport
there was a football match	sport
his team won the football match	sport
that restaurant is famous	not
he had his lunch in a restaurant	not

- 类条件概率：

- $P(\text{football} | \text{sport})$ 估计为 $3/15$ (sport 类别单词数 $4+5+6$)

- 拉普拉斯平滑处理，分子加1，分母加19：

- $P(\text{football} | \text{sport}) = (3+1)/(15+19)$ (单词表 $4+4+4+4+3=19$)
 - $P(\text{lunch} | \text{sport})$ 计算为 $(0+1)/(15+19)$



小结

1. 概述
2. 概率相关知识
3. 贝叶斯分类原理
4. 朴素贝叶斯分类器
5. 例题



谢谢！

