



福建師範大學
FUJIAN NORMAL UNIVERSITY

《机器学习》

【第九章-人工神经网络】

神经网络中的损失函数与BP算法
黄锐泓

本节要点

1. 损失函数

2. 反向传播算法与梯度下降



损失函数(Loss Function)

什么是损失函数？

损失函数(Loss Function)也可称为代价函数(Cost Function)或误差函数(Error Function)，**用于衡量预测值与实际值的偏离程度**。一般来说，我们在进行机器学习任务时，使用的每一个算法都有一个目标函数(Objective Function)，算法便是对这个目标函数进行优化，特别是在分类或者回归任务中，便是使用损失函数(Loss Function)作为其目标函数。机器学习的目标就是**希望预测值与实际值偏离较小，也就是希望损失函数较小，也就是所谓的最小化损失函数**。



损失函数 (Loss Function)

什么是损失函数？

损失函数是用来评价模型的预测值 $\hat{y} = f(x)$ 与真实值 y 的差异。它是一个非负实值函数。通常使用 $L(y, f(x))$ 来表示，损失函数越小，模型的性能就越好。



损失函数 (Loss Function)

什么是损失函数？

两个常用的损失函数

平方误差与交叉熵



平方误差(mean squared error, MSE)

MSE

对于一个**回归任务**，假设输入 x 的标签为 y ， $f(x)$ 是模型的预测值，平方误差损失函数用于描述模型的预测值与真实标签之间的欧式距离，距离越小越好

$$MSE = \frac{1}{2} (y - f(x))^2$$



平方误差(mean squared error, MSE)

MSE

对于一个**回归任务**，假设输入 x 的标签为 y ， $f(x)$ 是模型的预测值，平方误差损失函数用于描述模型的预测值与真实标签之间的欧式距离，距离越小越好

$$MSE = \frac{1}{2} (y - f(x))^2$$

真实值

预测值

真实值和预测值的差异/距离



交叉熵 (cross entropy)

交叉熵

对于一个**K-分类**任务，假设输入 x 的类别标签为 y 。定义 $\mathbf{q} = [q_1, q_2, q_3, \dots, q_k]$ 表示属于每个类别的期望概率分布，则

$$q_i = \begin{cases} 1, & i = y \\ 0, & \text{otherwise} \end{cases}$$

记神经网络模型的输出为： $f(x) = \mathbf{p} = [p_1, p_2, p_3, \dots, p_k]$

交叉熵损失函数用于衡量两个分布 $\mathbf{q}$ 和 $\mathbf{p}$ 之间的差异性，值越小越好

$$CrossEntropy = - \sum_{i=1}^k q_i \log(p_i)$$



损失函数 (Loss Function)

什么是损失函数？

两个常用的损失函数

一些其它损失函数



损失函数 (Loss Function)

Hinge Loss

对数损失函数

指数损失函数

二值交叉熵 (binary cross entropy)

绝对值损失函数

.....



反向传播算法与梯度下降

什么是反向传播算法(Backpropagation, BP)

BP对深度学习/神经网络来说是一个**非常重要的算法**

反向传播是“误差反向传播”的简称，是一种与最优化方法（如梯度下降法）结合使用的，用来训练人工神经网络的常见方法。该方法对网络中所有**权重**计算**损失函数的梯度**。它通过计算损失函数关于网络参数的梯度，并将梯度**沿着网络进行反向传播**，结合梯度下降法以**更新网络参数**。




反向传播算法与梯度下降

模型优化

回顾一下神经网络，假设我们有一个如下3层的MLP，隐藏层和输出层的激活函数均为sigmoid，记为 $\varphi(\cdot)$ ：

$$y = \varphi \left(W^{(2)T} \varphi(W^{(1)T} X) \right)$$

输出层



隐藏层

输入层




反向传播算法与梯度下降

模型优化

回顾一下神经网络，假设我们有一个如下3层的MLP，隐藏层和输出层的激活函数均为sigmoid，记为 $\varphi(\cdot)$ ：

$$f(x) = \varphi \left(\mathbf{W}^{(2)T} \varphi(\mathbf{W}^{(1)T} X) \right)$$

输出层



隐藏层

输入层


$$f(x) = \varphi \left(\sum_{j=0}^3 w^{(2)}_{kj} \cdot \varphi \left(\sum_{i=0}^2 w^{(1)}_{ji} x_i \right) \right)$$



反向传播算法与梯度下降

已知激活函数，
sigmoid

已知，模型输入数据

$$f(x) = \varphi\left(\sum_{j=0}^3 w^{(2)}_{kj} \cdot \varphi\left(\sum_{i=0}^2 w^{(1)}_{ji} \cdot x_i\right)\right)$$

未知权重参数，
介于隐藏层与输出层之间

未知权重参数，
介于输入层与隐藏层之间

找到模型合适的参数



优化的最终目标：降低模型预测值与实际值的偏离程度



反向传播算法与梯度下降

如何寻找合适的参数使得模型预测值接近实际值？

1. 通常我们“随机”初始化神经网络的参数/权重。因此，我们得到的预测值也相对随机（与实际值相去甚远）。
2. 因此，我们希望有一种更新方法使神经网络的**权重更准确**，这样我们得到的**预测值将更准确**。

↓

$$E = \frac{1}{2} (y - f(x))^2$$


↓

$$w_{i+1} \leftarrow w_i + \Delta w_i$$




反向传播算法与梯度下降

如何寻找合适的参数使得模型预测值接近实际值？



反向传播算法与梯度下降



如何寻找合适的参数使得模型预测值接近实际值？



反向传播算法与梯度下降

如何寻找合适的参数使得模型预测值接近实际值？



梯度下降法 (Gradient Descent)



反向传播算法与梯度下降

如何寻找合适的参数使得模型预测值接近实际值？


梯度下降法 (Gradient Descent)



反向传播算法与梯度下降

对 $E = \frac{1}{2}(y - f(x))^2$ 中参数求偏导: $\frac{\partial E}{\partial w_i}$

根据 w_i 偏导结果更新 w_i , $w_{i+1} \leftarrow w_i + \Delta w_i$, 其中 $\Delta w = -\eta \frac{\partial E}{\partial w_i}$, η 为学习率 (learning rate) 控制参数更新快慢。



反向传播算法与梯度下降

对如下三层神经网络我们定义， h_1 的输入为 $a^{(1)}_1$ ，输出为 z_1 ，输出层的输入为 $a^{(2)}$ ，输出为 $f(x)$

$$f(x) = \varphi(a^{(2)})$$


$$a^{(2)} = \left(\sum_{j=0}^3 w^{(2)}_{kj} z_j \right)$$

$$z_1 = \varphi(a^{(1)}_1)$$

$$a^{(1)}_1 = \left(\sum_{i=0}^2 w^{(1)}_{1i} x_i \right)$$

$$f(x) = \varphi\left(\sum_{j=0}^3 w^{(2)}_{kj} \cdot \varphi\left(\sum_{i=0}^2 w^{(1)}_{ji} x_i\right)\right)$$

$$E = \frac{1}{2} (y - f(x))^2$$



反向传播算法与梯度下降

若对 E 中参数 $w^{(2)}_{kj}$ 求偏导，即 $\frac{\partial E}{\partial w^{(2)}_{kj}}$


$$f(x) = \varphi(a^{(2)})$$

$$E = \frac{1}{2} (y - f(x))^2$$

$$a^{(2)} = \left(\sum_{j=0}^3 w^{(2)}_{kj} z_j^{(1)} \right)$$

$$z_1 = \varphi(a^{(1)}_1)$$

$$a^{(1)}_1 = \left(\sum_{i=0}^2 w^{(1)}_{1i} x_i \right)$$



$$\frac{\partial E}{\partial w^{(2)}_{kj}} = \frac{\partial E}{\partial f(x)} \frac{\partial f(x)}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial w^{(2)}_{kj}}$$



由链式法则 (chain rule) 可得，
我们需要分别求解 $\frac{\partial E}{\partial f(x)}$ 、 $\frac{\partial f(x)}{\partial a^{(2)}}$ 以
及 $\frac{\partial a^{(2)}}{\partial w^{(2)}_{kj}}$



反向传播算法与梯度下降

若对 E 中参数 $w^{(2)}_{kj}$ 求偏导，即 $\frac{\partial E}{\partial w^{(2)}_{kj}}$

$$\frac{\partial E}{\partial w^{(2)}_{kj}} = \frac{\partial E}{\partial f(x)} \frac{\partial f(x)}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial w^{(2)}_{kj}}$$

$$E = \frac{1}{2}(y - f(x))^2$$

(1) $\frac{\partial E}{\partial f(x)} = \frac{\partial \frac{1}{2}(y - f(x))^2}{\partial f(x)}$

$$= (y - f(x)) \frac{\partial (y - f(x))}{\partial f(x)} = -(y - f(x))$$



反向传播算法与梯度下降

若对 E 中参数 $w^{(2)}_{kj}$ 求偏导, 即 $\frac{\partial E}{\partial w^{(2)}_{kj}}$

$$\frac{\partial E}{\partial w^{(2)}_{kj}} = \frac{\partial E}{\partial f(x)} \frac{\partial f(x)}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial w^{(2)}_{kj}}$$

$$E = \frac{1}{2} (y - f(x))^2$$

(1)

$$\frac{\partial E}{\partial f(x)} = \frac{\partial \frac{1}{2}(y-f(x))^2}{\partial f(x)}$$

$$= (y - f(x)) \frac{\partial (y - f(x))}{\partial f(x)} = -(y - f(x))$$

$$f(x) = \varphi(a^{(2)})$$

(2)

$$\frac{\partial f(x)}{\partial a^{(2)}} = \frac{\partial \varphi(a^{(2)})}{\partial a^{(2)}}$$

$$= \varphi(a^{(2)}) \cdot (1 - \varphi(a^{(2)})) = f(x) \cdot (1 - f(x))$$

$$\varphi(\cdot) \text{ 是激活函数sigmoid,} \\ \varphi'(x) = \varphi(x)(1 - \varphi(x))$$



反向传播算法与梯度下降

若对 E 中参数 $w^{(2)}_{kj}$ 求偏导, 即 $\frac{\partial E}{\partial w^{(2)}_{kj}}$

$$\frac{\partial E}{\partial w^{(2)}_{kj}} = \frac{\partial E}{\partial f(x)} \frac{\partial f(x)}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial w^{(2)}_{kj}}$$

$$E = \frac{1}{2} (y - f(x))^2$$

(1)

$$\frac{\partial E}{\partial f(x)} = \frac{\partial \frac{1}{2}(y-f(x))^2}{\partial f(x)}$$

$$= (y - f(x)) \frac{\partial (y - f(x))}{\partial f(x)} = -(y - f(x))$$

$$f(x) = \varphi(a^{(2)})$$

(2)

$$\frac{\partial f(x)}{\partial a^{(2)}} = \frac{\partial \varphi(a^{(2)})}{\partial a^{(2)}}$$

$$= \varphi(a^{(2)}) \cdot (1 - \varphi(a^{(2)})) = f(x) \cdot (1 - f(x))$$

$$a^{(2)} = \left(\sum_{j=0}^3 w^{(2)}_{kj} z_j \right)$$

(3)

$$\frac{\partial a^{(2)}}{\partial w^{(2)}_{kj}} = \frac{\partial (\sum_{j=0}^3 w^{(2)}_{kj} z_j)}{\partial w^{(2)}_{kj}} = z_j$$



反向传播算法与梯度下降

若对 E 中参数 $w^{(2)}_{kj}$ 求偏导，即 $\frac{\partial E}{\partial w^{(2)}_{kj}}$

$$\frac{\partial E}{\partial w^{(2)}_{kj}} = \frac{\partial E}{\partial f(x)} \frac{\partial f(x)}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial w^{(2)}_{kj}}$$

$$\frac{\partial E}{\partial w^{(2)}_{kj}} = -(y - f(x)) \cdot (f(x) \cdot (1 - f(x))) \cdot z_j$$

$$\frac{\partial E}{\partial f(x)} = \frac{\partial \frac{1}{2}(y - f(x))^2}{\partial f(x)}$$

$$= (y - f(x)) \frac{\partial (y - f(x))}{\partial f(x)} = -(y - f(x))$$

$$\frac{\partial f(x)}{\partial a^{(2)}} = \frac{\partial \varphi(a^{(2)})}{\partial a^{(2)}}$$

$$= \varphi(a^{(2)}) \cdot (1 - \varphi(a^{(2)})) = f(x) \cdot (1 - f(x))$$

$$\frac{\partial a^{(2)}}{\partial w^{(2)}_{kj}} = \frac{\partial (\sum_{j=0}^3 w^{(2)}_{kj} z_j)}{\partial w^{(2)}_{kj}} = z_j$$



反向传播算法与梯度下降

若对 E 中参数 $w^{(1)}_{ji}$ 求偏导, 即 $\frac{\partial E}{\partial w^{(1)}_{ji}}$


$$f(x) = \varphi(a^{(2)})$$

$$E = \frac{1}{2} (y - f(x))^2$$

$$a^{(2)} = \left(\sum_{j=0}^3 w^{(2)}_{kj} z_j \right)$$

$$z_1 = \varphi(a^{(1)}_1)$$

$$a^{(1)}_1 = \left(\sum_{i=0}^2 w^{(1)}_{1i} x_i \right)$$



$$\frac{\partial E}{\partial w^{(1)}_{ji}} = \frac{\partial E}{\partial f(x)} \frac{\partial f(x)}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial z_j} \frac{\partial z_j}{\partial a^{(1)}_j} \frac{\partial a^{(1)}_j}{\partial w^{(1)}_{ji}}$$



由链式法则 (chain rule) 可得, 我们还需要求解 $\frac{\partial a^{(2)}}{\partial z_j}$ 、 $\frac{\partial z_j}{\partial a^{(1)}_j}$ 以及

$$\frac{\partial a^{(1)}_j}{\partial w^{(1)}_{ji}}$$



反向传播算法与梯度下降

若对 E 中参数 $w^{(1)}_{ji}$ 求偏导，即 $\frac{\partial E}{\partial w^{(1)}_{ji}}$

已知

$$\frac{\partial E}{\partial w^{(1)}_{ji}} = \frac{\partial E}{\partial f(x)} \frac{\partial f(x)}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial z_j} \frac{\partial z_j}{\partial a^{(1)}_j} \frac{\partial a^{(1)}_j}{\partial w^{(1)}_{ji}}$$



反向传播算法与梯度下降

若对 E 中参数 $w^{(1)}_{ji}$ 求偏导, 即 $\frac{\partial E}{\partial w^{(1)}_{ji}}$

已知

$$\frac{\partial E}{\partial w^{(1)}_{ji}} = \frac{\partial E}{\partial f(x)} \frac{\partial f(x)}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial z_j} \frac{\partial z_j}{\partial a^{(1)}_j} \frac{\partial a^{(1)}_j}{\partial w^{(1)}_{ji}}$$

$$a^{(2)} = \left(\sum_{j=0}^3 w^{(2)}_{kj} z_j \right)$$

(1)

$$\begin{aligned} \frac{\partial a^{(2)}}{\partial z_j} &= \frac{\partial (\sum_{j=0}^3 w^{(2)}_{kj} z_j)}{\partial z_j} \\ &= w^{(2)}_{kj} \end{aligned}$$



反向传播算法与梯度下降

若对 E 中参数 $w^{(1)}_{ji}$ 求偏导, 即 $\frac{\partial E}{\partial w^{(1)}_{ji}}$

已知

$$\frac{\partial E}{\partial w^{(1)}_{ji}} = \frac{\partial E}{\partial f(x)} \frac{\partial f(x)}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial z_j} \frac{\partial z_j}{\partial a^{(1)}_j} \frac{\partial a^{(1)}_j}{\partial w^{(1)}_{ji}}$$

$$a^{(2)} = \left(\sum_{j=0}^3 w^{(2)}_{kj} z_j \right)$$

(1)

$$\begin{aligned} \frac{\partial a^{(2)}}{\partial z_j} &= \frac{\partial (\sum_{k=0}^3 w^{(2)}_{kj} z_j)}{\partial z_j} \\ &= w^{(2)}_{kj} \end{aligned}$$

$$z_j = \varphi(a^{(1)}_j)$$

(2)

$$\begin{aligned} \frac{\partial z_j}{\partial a^{(1)}_j} &= \frac{\partial \varphi(a^{(1)}_j)}{\partial a^{(1)}_j} \\ &= \varphi(a^{(1)}_j) \cdot (1 - \varphi(a^{(1)}_j)) = z_j \cdot (1 - z_j) \end{aligned}$$



反向传播算法与梯度下降

若对 E 中参数 $w^{(1)}_{ji}$ 求偏导, 即 $\frac{\partial E}{\partial w^{(1)}_{ji}}$

已知

$$\frac{\partial E}{\partial w^{(1)}_{ji}} = \frac{\partial E}{\partial f(x)} \frac{\partial f(x)}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial z_j} \frac{\partial z_j}{\partial a^{(1)}_j} \frac{\partial a^{(1)}_j}{\partial w^{(1)}_{ji}}$$

$$a^{(2)} = \left(\sum_{j=0}^3 w^{(2)}_{kj} z_j \right)$$

(1)

$$\frac{\partial a^{(2)}}{\partial z_j} = \frac{\partial (\sum_{k=0}^3 w^{(2)}_{kj} z_j)}{\partial z_j}$$
$$= w^{(2)}_{kj}$$

$$z_j = \varphi(a^{(1)}_j)$$

(2)

$$\frac{\partial z_j}{\partial a^{(1)}_j} = \frac{\partial \varphi(a^{(1)}_j)}{\partial a^{(1)}_j}$$
$$= \varphi(a^{(1)}_j) \cdot (1 - \varphi(a^{(1)}_j)) = z_j \cdot (1 - z_j)$$

$$a^{(1)}_j = \left(\sum_{i=0}^2 w^{(1)}_{ji} x_i \right)$$

(3)

$$\frac{\partial a^{(1)}_j}{\partial w^{(1)}_{ji}} = \frac{\partial (\sum_{i=0}^2 w^{(1)}_{ji} x_i)}{\partial w^{(1)}_{ji}} = x_i$$



反向传播算法与梯度下降

若对 E 中参数 $w^{(1)}_{ji}$ 求偏导, 即 $\frac{\partial E}{\partial w^{(1)}_{ji}}$

$$\frac{\partial E}{\partial w^{(1)}_{ji}} = \frac{\partial E}{\partial f(x)} \frac{\partial f(x)}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial z_j} \frac{\partial z_j}{\partial a^{(1)}_j} \frac{\partial a^{(1)}_j}{\partial w^{(1)}_{ji}}$$

$$\frac{\partial a^{(2)}}{\partial z_j} = \frac{\partial (\sum_{k=0}^3 w^{(2)}_{kj} z_k)}{\partial z_j} = w^{(2)}_{kj}$$

$$\frac{\partial z_j}{\partial a^{(1)}_j} = \frac{\partial \varphi(a^{(1)}_j)}{\partial a^{(1)}_j}$$

$$= \varphi(a^{(1)}_j) \cdot (1 - \varphi(a^{(1)}_j)) = z_j \cdot (1 - z_j)$$


$$\frac{\partial a^{(1)}_j}{\partial w^{(1)}_{ji}} = \frac{\partial (\sum_{i=0}^2 w^{(1)}_{ji} x_i)}{\partial w^{(1)}_{ji}} = x_i$$

$$\frac{\partial E}{\partial w^{(1)}_{ji}} = - (y - f(x)) \cdot (f(x) \cdot (1 - f(x))) \cdot w^{(2)}_{kj} \cdot (z_j \cdot (1 - z_j)) \cdot x_i$$



反向传播算法与梯度下降

综上，对于如下三层MLP，我们可知其参数的偏导分别为：



$$\frac{\partial E}{\partial w^{(1)}_{ji}} = -(y - f(x)) \cdot (f(x) \cdot (1 - f(x))) \cdot w^{(2)}_{kj} \cdot (z_j \cdot (1 - z_j)) \cdot x_i$$

$$\frac{\partial E}{\partial w^{(2)}_{kj}} = -(y - f(x)) \cdot (f(x) \cdot (1 - f(x))) \cdot z_j$$



反向传播算法与梯度下降

综上，对于如下三层MLP，我们可知其参数的偏导分别为：

$$\frac{\partial E}{\partial w^{(1)}_{ji}} = -(y - f(x)) \cdot (f(x) \cdot (1 - f(x))) \cdot w^{(2)}_{kj} \cdot (z_j \cdot (1 - z_j)) \cdot x_i$$

$$\frac{\partial E}{\partial w^{(2)}_{kj}} = -(y - f(x)) \cdot (f(x) \cdot (1 - f(x))) \cdot z_j$$

若参数的更新方法为： $w_{i+1} \leftarrow w_i + \Delta w_i$ ，其中 $\Delta w = -\eta \frac{\partial E}{\partial w_i}$ ，则


$$\Delta w^{(1)}_{ji} = \eta (y - f(x)) \cdot (f(x) \cdot (1 - f(x))) \cdot w^{(2)}_{kj} \cdot (z_j \cdot (1 - z_j)) \cdot x_i$$

$$\Delta w^{(2)}_{kj} = \eta (y - f(x)) \cdot (f(x) \cdot (1 - f(x))) \cdot z_j$$



反向传播算法与梯度下降

计算得到神经网络中所有节点的数值




向前传播
Forward
propagation

反向传播
backward
propagation

根据“向前传播”过程中得到的数值更新所有参数



反向传播算法与梯度下降



反向传播算法与梯度下降

梯度消失与梯度爆炸

梯度消失：反向传播时前面层的梯度依赖于后面层梯度的乘积，如果累乘小于1的数，随着层数的增加前面层梯度会呈指数级的趋于0。

梯度爆炸：累乘的数大于1，导致梯度非常大。

梯度消失与梯度爆炸的表现

梯度消失：

- 模型无法更新、损失函数几乎保持不变

梯度爆炸：

- 模型不稳定，更新过程中的损失出现显著变化。
- 训练过程中，模型损失变成 NaN。



反向传播算法与梯度下降

梯度消失与梯度爆炸产生的原因

梯度消失：

- 隐藏层的层数过多。
- 采用了不合适的激活函数。

梯度爆炸：

- 隐藏层的层数过多。
- 权重的初始化值过大。

解决方法

- (1) 减小网络层数。
- (2) 调整学习率，（梯度消失增加、梯度爆炸减小）。
- (3) 更换激活函数（ReLU、Leaky ReLU、ELU、SELU等）。
- (4) Batch Normalization。
- (5) 更换初始化方法。
- (6) 使用残差模块（ResNet）。
- (7) RNN更换为LSTM结构。
- (8) 梯度裁剪（超过设定阈值其变为值域）。
- (9) L1、L2正则化。
- (10) 预训练+微调：



小结

1. 损失函数
2. 反向传播算法与梯度下降（原理、推导过程）



谢谢！

